



第〇章：“人工智能与科学”背景介绍




从经典AI到基础模型，以及科学问题的数据表示

黄刚 成都理工大学




2026年9月

1. 机器学习基础：Andrew Ng, Machine Learning, (bilibili)；李宏毅机器学习深度学习系列课程 (Hung-yi Lee)
2. <https://indico.itp.ac.cn/event/31/>
2. Simon J. D. Prince, 《理解深度学习》(Understanding Deep Learning) 清华大学出版社，2025
3. S. Russel, P. Norvig, Artificial Intelligence: A modern Approach, Printice-Hall, Englewood Cliffs, NJ, (4th Ed)
4. David L. Poole, Alan K. Mackworth, Artificial Intelligence: Foundations of computational agents (3rd Ed), Cambridge Press, 2023

主要内容



ML



AI, Agent

1. 区分符号主义、机器学习、深度学习、基础模型和智能体
2. 把科学问题写成输入、输出、先验、损失、指标和数据划分
3. 使用向量、矩阵和张量表示科学数据
4. 区分监督、无监督、自监督和强化学习

人工智能与科学问题

《AI在科学中的应用》

感知 → 表示 → 推理或预测 → 决策 → 行动

定义

人工智能研究如何设计能在给定环境中完成任务的计算系统。系统可以模拟人的部分能力，但不要求复制人脑。

符号主义与搜索	机器学习与深度学习	基础模型与智能体
规则、逻辑、状态空间	从数据估计规律	大规模自监督预训练
规划、约束、博弈	表示学习、预测、控制	多任务、多模态、工具调用
知识由人显式写入 (Prolog, Datalog)	知识隐含在参数中 (CNN, RNN, ResNet 等)	模型与外部工具共同工作 (基础模型 : GPT, DeepSeek; 智能体: Coding Agent, AutoGPT,..)

AI技术发展的层次变化：从解决特定任务的模型，到可迁移到大量任务的通用模型，再到能够自主完成多步骤任务的系统。三类方法仍会共存。

规则

条件成立时推出结论或执行动作。

$T < 0\text{ }^{\circ}\text{C} \Rightarrow \text{水可能结冰}$

逻辑

用形式化语句和推理规则推出新结论。

$A \Rightarrow B, A \Rightarrow B$

过程是清晰的，困难是复杂世界中的规则难以穷举，知识获取成本高。



任何路径问题都需要说明：

- ▶ 状态、起点与目标
- ▶ 允许的状态转移
- ▶ 每一步的代价
- ▶ 探索状态的顺序


同一算法可以处理城市路线、机器人路径、实验流程和博弈状态。

数独可写成三部分：

变量 + 取值域 + 约束

- ▶ 变量：81个格子
- ▶ 取值域：1到9
- ▶ 约束：每行、每列、每个九宫格不重复

6			7	9	8			4
		8				1		
	3						8	
4				2				8
5			4		9			2
3				6				7
	2						4	
		6				9		
7			6	1	3			5



科学问题中，对称性、化学价态、边界条件和守恒律也可作为约束。

From complex to simple : hierarchical free-energy landscape renormalized in deep neural networks

Hajime Yoshino^{1,2*}

¹ Cybermedia Center, Osaka University, Toyonaka, Osaka 560-0043, Japan

² Graduate School of Science, Osaka University, Toyonaka, Osaka 560-0043, Japan

* yoshino@cmc.osaka-u.ac.jp

April 13, 2020

Abstract

We develop a statistical mechanical approach based on the replica method to study the design space of deep and wide neural networks constrained to meet a large number of training data. Specifically, we analyze the configuration space of the synaptic weights and neurons in the hidden layers in a simple feed-forward perceptron network for two scenarios: a setting with random inputs/outputs and a teacher-student setting. By increasing the strength of constraints, i.e. increasing the number of training data, successive 2nd order glass transition (random inputs/outputs) or 2nd order crystalline transition (teacher-student setting) take place layer-by-layer starting next to the inputs/outputs boundaries going deeper into the bulk with the thickness of the solid phase growing logarithmically with the data size. This implies the typical storage capacity of the network grows exponentially fast with the depth. In a deep enough network, the central part remains in the liquid phase. We argue that in systems of finite width N , the weak bias field can remain in the center and plays the role of a symmetry-breaking field that connects the opposite sides of the system. The successive glass transitions bring about a hierarchical free-energy landscape with ultrametricity, which evolves in space: it is most complex close to the boundaries but becomes renormalized into progressively simpler ones in deeper layers. These observations provide clues to understand why deep neural networks operate efficiently. Finally, we present some numerical simulations of learning which reveal spatially heterogeneous glassy dynamics truncated by a finite width N effect.

1 Introduction

Machine learning by deep neural networks (DNN) is successful in numerous applications [1]. However, it remains challenging to understand why DNNs actually work so well. Given the enormous parameter space, which is typically orders of magnitude larger than that of the data space, and the flexibility of non-linear functions used in DNNs, it is not very surprising that they can express complex data [2]. What is surprising is that such extreme machines can be put under control. On one hand, one would naturally fear that learning such a huge number of parameters would be extremely time-consuming because the fitness landscape is presumably quite complex with many local traps. Moreover, over-fitting or poor generalization ability seems unavoidable in such over-parametrized machines. We would not dare to fit a data set of 10 points by a 100th order polynomial, which does not make sense usually. Quite unexpectedly, these issues seem to be somehow resolved in practice and such extreme machines turned out to be very useful. Thus it is a very interesting scientific problem to uncover what is going on in DNNs [3, 4]. This is also important in practice because we wish to use DNNs not merely as mysterious black boxes but control/design them in rational ways. In the present paper we develop a statistical mechanical approach based on the replica method to obtain some insights into these issues.

In this paper, we investigate a class of simple machines made of feed-forward networks of layered perceptrons whose depth is L and the width is N (see Fig. 1). Such a machine is parametrized by a configuration of synaptic weights in the hidden layers. We consider the coupling between adjacent layers are *global* in the sense that all neurons in the l -th layer are connected to all neurons in $l + 1$ -th layer. For a given pair of inputs/outputs patterns imposed on the input and output layers, there can be different realizations of the synaptic weights that match the same constraints. We call each of them as a 'solution'. Following the work of Gardner [5, 6] for the single perceptron, we consider statistical mechanics of the design space of the neural network which is compatible with a large number $M = \alpha N$ patterns of training data, in the large width $N \rightarrow \infty$ limit with fixed α . For the choice of the training data, we consider two simple scenarios: 1) pairs of purely random inputs/outputs patterns 2) teacher-student setting - pairs of random input and the corresponding output of a teacher machine with random synaptic weights are handed over to a student machine.

From a broader perspective, the setting 1) can be viewed as a random constraint satisfaction problem (CSP) [7, 8], which is deeply related to the physics of glass transitions and




游戏（博弈、game）

问：从这个游戏 (game)，你看到了什么？

1. 这里面存在对抗，存在一个我们无法控制的手；
2. 游戏，是一个搜索问题，其最优解是帮助我们赢得比赛的**策略**：（不是一个引向目标的动作序列）

(A, A') , (B, B') , (C, C') , ...



井字棋 (Tic-tac-toe)

把博弈写成搜索问题

状态 (state)

局面的完整描述。

井字棋：棋盘上 X/O/空格的分布。

动作 (action)

当前可选择的操作。

井字棋：在哪个空格落子。

效用函数 (utility)

终局好坏的数值化。

井字棋：赢 +1，平 0，输 -1。

MAX / MIN

MAX：我方，努力让效用变大

MIN：对手/不利因素，努力让效用变小

策略 (strategy)

不是一步动作，而是“在每种可能局面下怎么走”的完整计划。

终止

搜到终局用真实效用；搜不到终局时，用评价函数估计。

Minimax：自底向上的推理

核心假设：我方理性；对手也理性。每一步都要考虑：对手接下来会怎样削弱我。

递归定义


若 s 是终局： $V(s)=U(s)$

若 s 是 MAX 节点： $V(s)=\max V(\text{Result}(s,a))$


若 s 是 MIN 节点： $V(s)=\min V(\text{Result}(s,a))$

计算步骤

1. 展开有限深度搜索树（3层）
2. 给叶子节点打分 (3,12,8 ; 2,4,6 ; 14, 5, 2)
3. 从叶子向根回传
4. MAX 层取最大，MIN 层取最小
5. 根节点对应的动作就是当前选择（a1）



α - β 剪枝



符号含义

α : 沿路径上 MAX 已经能保证的最低收益。

β : 沿路径上 MIN 已经能保证的最高收益。

剪枝条件 : $\beta \leq \alpha$ 。

1. 先看左子树 B

B 是 MIN 节点 : $\min(3, 12, 8) = 3$ 。

根节点 A 是 MAX, 因此 α_A 更新为 3。

2. 再看中间子树 C

C 是 MIN 节点, 先看到第一个叶子 2, $\beta_C = 2$ 。

此时 $\beta_C = 2 \leq \alpha_A = 3$, C 后面 4、6 不可能让根节点更好, 剪掉。

3. 最终选择 : D 的最小值为 2 ; 根节点 $\max(3, 2, 2) = 3$, 选择 B。结果与完整搜索一样, 但少算分支。

1. 对抗搜索

当未来局面会被对手或环境改变时，决策就不只是找路径，而是找策略。

2. Minimax

MAX 假设自己会选最大收益；MIN 假设对手会选最小收益；数值从叶子回传到根。

3. α - β 剪枝

剪掉不可能改变最终选择的分支；结果不变，计算更少。

4. AI for Science

科研决策常有不确定性和资源约束：用 Minimax 思想，可以把“最坏情况仍较好”作为稳健决策原则。

先把问题写成“状态—动作—结果—效用”，对抗搜索的算法就有用了。

从科学问题到AI任务

科学问题	AI任务	可能的输出
识别矿物、天体或细胞类型	分类（CNN, ResNet, Transformer, 随机森林）	离散的类别及类别 概率 （ $x \rightarrow y$, y 为有限类别）
从结构预测材料性质	回归（神经网络, GNN, 高斯过程）	连续数值和不确定性。（ $x \rightarrow y$, $y \in R$ ）
从大量样本中发现不同结构	聚类/降维（K-means, GMM, 深度聚类）	分组或低维表示（找到数据内部的自然分组）
从实验观测推断未知物理参数	反问题/参数推断（贝叶斯推断, 神经网络, PINN）	参数估计或后验分布
从高维数据中寻找少数关键自由度	降维/表示学习（PCA, Autoencoder）	低维表示、潜变量
根据条件设计新分子结构或材料	条件生成（VAE, GAN, 扩散模型, 生成式Transformer）	满足约束的候选新结构
根据已有实验选择下一组实验条件	序贯决策（强化学习, 贝叶斯优化, 主动学习）	下一动作或实验条件
根据初始条件预测系统未来状态	预测/动力学学习	未来状态、轨迹（ $(x(t), \text{条件})$ $\rightarrow x(t + 1)$ ）

科学问题与AI任务

先定义X 和y

输入是什么？ 输出是什么？ 有无标准答案？

科学问题： 这张显微镜图形中的细胞属于哪一种类型？

输入： 图像x

AI任务： 分类


输出： $P(y = A | x) = 0.05, P(y = B | x) = 0.90, P(y = C | x) = 0.05$

科学问题： 已知材料的组成和结构，预测其带隙。

输入： $x = (\text{组成}, \text{结构})$

AI任务： 回归

输出： $y = E_g (E_g \in R)$.



Ferreira, Silveira, Sci. Rep. **14**, 9031 (2024)

如果没有 y , 就可能进入**无监督学习**.

例如, 有高维**粒子构型**的集合

$$\{x_1, x_2, \dots, x_N\}$$

但不知道它们属于什么相 (没有 y_i) 。


科学问题 : 这些构型中有没有自然出现的不同状态 ?

输入 : $\{x_1, x_2, \dots, x_N\}$

AI任务 : **聚类/表示学习/降维**

输出 : $x \in R^{6400} \rightarrow z \in R^5$ (看在低维空间里数据是否会自动分离)

例如, 对Ising模型, 把 80×80 Ising 自旋构型看作 6400 维输入, 在没有**温度**和**磁化强度**标签的情况下训练 autoencoder, 让网络**学习低维表示**。之后再用**温度**和**磁化强度**解释潜空间, 发现铁磁相和顺磁相形成了不同区域。



反问题 (inverse problem)

例如，你测得了散射谱

$$I(q)$$

但想知道被测系统的参数


$$\theta = (R, \rho, T \dots)$$

科学问题： 如何从观测结果反推产生这些结果的参数（或原因）？

输入： 实验测量出的关联函数，如衍射光谱，散射光谱，...

AI任务： 聚类/表示学习/降维

输出： $p(\theta|D)$ (参数的后验概率分布)



两个问题

问题1：给定一个分子，预测其溶解度。（这是一个什么问题？）

$$x_{\text{mol}} \rightarrow y_{\text{solubility}}$$

问题2：给定目标溶解度，设计一种可能的分子？

$$y_{\text{desired}} \rightarrow x_{\text{mol}}$$

预测与生成

问题1：给定一个分子，预测其溶解度。（这是一个什么问题？）

$$x_{\text{mol}} \rightarrow y_{\text{solubility}}$$

问题2：给定目标溶解度，设计一种可能的分子？

$$y_{\text{desired}} \rightarrow x_{\text{mol}}$$

前者是回归问题，后者是条件生成。

二者实际上方向相反。

这在材料设计、药物设计中尤其重要。

选择下一次实验 和 普通预测

假设我们已经做了若干次实验：

$$D_t = \{(x_i, y_i)\}_{i=1, \dots, t}$$

问：下一次应该做哪个 x ？

$$D_t \rightarrow x_{t+1}.$$

做完后，获得 y_{t+1} . 数据集更新：

$$D_{t+1} = D_t \cup \{(x_{t+1}, y_{t+1})\}.$$

然后再选择下一次实验：

$$D_{t+1} \rightarrow x_{t+2}.$$

形成循环：预测 》 选择实验 》 实验 》 获得数据 》 更新模型

这就是**序贯决策**。

常见方法：Bayesian 优化；强化学习。

科学问题 → 数据表示 → AI任务

模型 → AI输出 → 科学解释和验证

注意：

1. AI输出 并不等于 科学结论！
2. AI（以神经网络为代表）不应该被当作产生数值答案的黑箱, 而应结合物理系统来理解模型结构, 数据, 损失函数和约束；模型输出还应与理论、守恒律、对称性、数值模拟或实验进行比较。

练习：将科学问题—AI视角来表述

请从自己的研究方向选择一个问题，写出：

1. 你的数据(输入 x)是什么？ 图像？时间序列？粒子坐标？光谱？文本？
2. 你想得到**输出** y 是什么？ 类别？连续的数值？**低维坐标**？参数？新结构？实验动作？
3. 有没有**已知的** y ？ 监督学习；无监督/自监督学习
4. 要预测已有对象，还是创造新对象？（**分类/回归**，生成模型）
5. 是**一次**预测，还是不断地判断下一步？（预测，贯序决策）
6. 有哪些**科学规律**必须满足？（守恒律/对称性、边界条件、量纲、微分方程）

最后问：应该选择什么模型？CNN，GNN，Transformer, PINN，...？

将科学问题转化为AI任务：

把科学目标明确为一个可计算的输入-输出关系、结构发现问题或决策问题；模型选择是这之后才发生的。

数据表示与相似性

《AI在科学中的应用》

数据集：样本、特征和标签

		特征 X						标签 y
动物		有鳍	有鳃	卵生	生活在水中	有鳞片	恒温	是鱼
样本👉	鲑鱼	1	1	1	1	1	0	1
	金鱼	1	1	1	1	1	0	1
	<u>鲤鱼</u>	<u>1</u>	<u>1</u>	<u>1</u>	<u>1</u>	<u>1</u>	<u>0</u>	<u>1</u>
	竹鲨	1	1	1	1	0	0	1
	鲸鱼	1	0	0	1	0	1	0
	海豚	1	0	0	1	0	1	0
	海龟	0	0	1	1	1	0	0
	青蛙	0	0	1	1	0	0	0
	猫	0	0	0	0	0	1	0
	鸵鸟	0	0	1	0	0	1	0

数据集：训练集、测试集；样本、特征和标签

特征 X

$$X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 \end{pmatrix} \in \{0, 1\}^{10 \times 6}$$

标签 y

$$\mathbf{y} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \in \{0, 1\}^{10}$$

样本、特征和标签

$$\boldsymbol{x} \in R^d \quad \rightarrow \quad y$$

d 个输入特征

要预测的目标

数据矩阵

$$\boldsymbol{X} \in R^{n \times d}$$

n 行表示样本， d 列表示特征。

标签或目标

$$y \in R^n \quad \text{或} \quad y \in \{1, \dots, K\}^n$$

回归目标连续，分类标签离散。

常见数据集：计算机视觉、自然语言处理和经典机器学习等类型。


计算机视觉 (CV)

MNIST：含 7 万 张手写数字图片（60,000 张训练，10,000 张测试），是图像分类入门的经典数据集；


CIFAR-10 / CIFAR-110：数万张 32×32 分辨率的小型彩色图片，分为 10 类或 100 类（如飞机、汽车、鸟等）；

ImageNet：有超过 1400 万张标注图片、两万多类别的大型视觉数据库，推动了深度学习和计算机视觉的飞速发展；

MS COCO：专注于目标检测、分割和图像描述的大型数据集，包含复杂的日常场景和精确的物体标注。



airplane
automobile
bird
cat
deer
dog
frog
horse
ship
truck



常见数据集：计算机视觉、自然语言处理和经典机器学习等类型。

自然语言处理 (NLP)

IMDB：包含 50,000 条电影评论，用于情感分类任务（判断评论是积极还是消极）。(IMDB_dataset.csv; 66 MB)

Sust/AG News / Reuters：路透社等新闻主题分类数据集，用于文本分类和主题识别。

SQuAD：斯坦福问答数据集，包含大量阅读理解问答对，用于训练机器阅读理解和问答系统模型。

About this file	
In this dataset, only two columns, including unique values and the other is Positive or negative.	
△ review The reviews of movies written by people.	△ sentiment The sentiment of movies is either positive or negative.
49582 unique values	2 unique values
One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. The...	positive
A wonderful little production. The filming technique is very unassuming- very old-time-B...	positive
I thought this was a wonderful way to spend time on a too hot summer weekend, sitting in the air con...	positive


常见数据集：计算机视觉、自然语言处理和经典机器学习等类型。

经典机器学习与数据分析

Iris (鸢尾花数据集)：含 150 个样本，分为三类鸢尾花，每类 4 个特征，是学习分类算法的初级数据集。
(<https://archive.ics.uci.edu/dataset/53/iris>)

Boston Housing (波士顿房价数据集)：含美国人口普查局收集的房屋及周边信息(用于回归预测算法的基准测试)。

Titanic (泰坦尼克号数据集)：含乘客生存状态、性别、年龄、舱位等信息 (学习二分类、数据清洗的经典案例)。



对象	数学形式	例子
标量	$x \in \mathbb{R}$	温度、能量、浓度、密度、...
向量	$\mathbf{x} \in \mathbb{R}^d$	一个样本的 d 个特征；速度、原子构型、原子环境、单词、人、...
矩阵	$\mathbf{X} \in \mathbb{R}^{n \times d}$	n 个样本组成的数据表、应力张量、应变张量、转动惯量张量、介电张量、Hessian矩阵、密度矩阵、...
张量	$\mathbf{X} \in \mathbb{R}^{H \times W \times C \times \dots}$	彩色图像(X_{ijc})、视频(X_{tijc})、时空场、批数据(X_{bhwc})、

神经网络的大量计算可以归结为矩阵乘法和张量运算。

注意：数学和物理中的张量是在坐标变换下按照特定规律变换的数学对象。

如，对于一个二阶张量 T_{ij} ，在坐标变换前后，其分量满足

$$T'_{ij} = \sum_{k,l} R_{ik} T_{jl} T_{kl}$$

NumPy中的数据表示和提取（见阅读材料和习题）

```
import numpy as np

# 行是样本，列是温度、压力和响应
X = np.array([
    [280.0, 0.90, 1.15],
    [290.0, 1.00, 1.28],
    [300.0, 1.10, 1.41],
])

print(X.shape)    # (3, 3)
print(X[0])       # 第一个样本
print(X[:, 0])    # 温度特征
```

距离与点积（习题）

欧氏距离

$$d(x, y) = |x - y|^2$$

用于衡量坐标空间中的接近程度。



余弦相似度

$$\cos \theta = (x^T y) / (|x||y|)$$

更关注方向，不直接比较向量长度。

相似性依赖表示方法，没有脱离任务的“唯一正确距离”。

特征尺度改变邻近关系



当温度约为300、浓度约为0.1时，原始欧氏距离几乎由温度决定。

$$z = (x - \mu) / \sigma$$

只在训练集上估计 μ 和 σ

否则会产生数据泄漏。

学习之分类

《AI在科学中的应用》

$$D = \{(\mathbf{x}^{(i)}, y^{(i)})\} \quad i = 1, \dots, n$$

学习函数 f_θ , 使预测 $f_\theta(\mathbf{x})$ 接近目标 y 。

- 分类：输出离散类别或类别概率
- 回归：输出连续数值

数据只有输入 $\{\mathbf{x}^{(i)}\}$ ，没有人工标签。

- 聚类：寻找相似样本组
- 降维：寻找低维结构
- 密度估计：描述数据分布
- 表示学习：学习适合后续任务的内部特征

聚类编号没有天然科学含义，需要结合领域变量解释。

从原始数据 X 自动构造输入 X' 和目标 y

$$X \rightarrow (X', y) \quad f_{\theta}(X') \approx y$$

语言模型例子

给定前面的Token, 预测下一个Token :

$$p(x_t \mid x_1, \dots, x_{t-1})$$

监督信号来自数据自身，使大规模无标注数据可以用于预训练。

智能体在环境中采取动作并获得奖励，目标是最大化累计回报。

状态 s_t $\rightarrow$ 策略 π $\rightarrow$ 动作 a_t $\rightarrow$ 环境 $\rightarrow r_t, s_{t+1}$

四类学习范式的区别

范式	监督信号	典型问题
监督学习	人工或实验标签	分类、回归
无监督学习	无显式标签	聚类、降维
自监督学习	数据自身构造目标	预训练、表示学习
强化学习	环境提供奖励	序贯决策、控制

训练集、验证集和测试集

数据子集	用途
训练集	拟合模型参数和预处理参数
验证集	选择模型、超参数和停止时机
测试集	在所有选择结束后进行一次最终评价

同一对象的重复测量、相邻时间点或近重复结构不应跨集合泄漏。

(3分) 提交一页答案：

将你的科研课题中的科学问题转化为AI 任务。