机器学习

3. 决策树算法

黄刚

成都理工大学物理学院

2026 年 10 月 22 日



1. 树的结构与预测
2. 分类树
3. 回归树
4. 训练与解释
5. 控制复杂度与评价

学习目标

- 理解决策树（分类树、回归树）；
- 理解信息熵、信息增益和 Gini 指数；
- 训练并解释分类树与回归树；
- 为下一步学习随机森林建立基础。

1 树的结构与预测

2 分类树

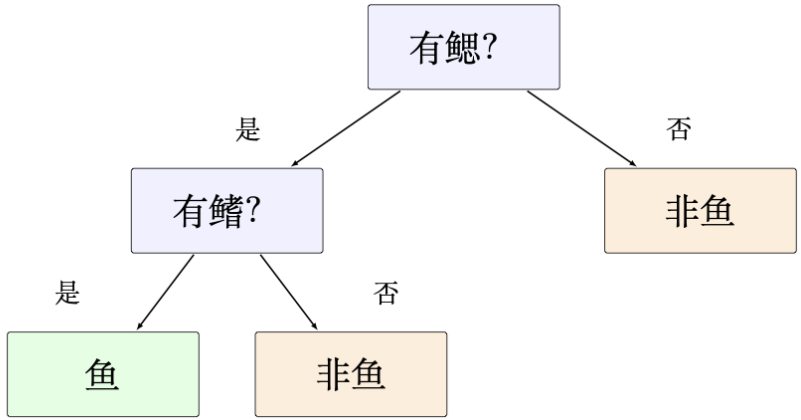
3 回归树

4 训练与解释

5 控制复杂度与评价

什么是决策树？(1)

- 根节点：全部训练样本；
- 内部节点：提出一个问题；
- 分支：问题的答案；
- 叶节点：最终预测。



判断是否为鱼的简单决策树

什么是决策树？(2)

决策树的基本结构

决策树（Decision Tree）是由节点和有向边组成的树状结构。节点可分为：

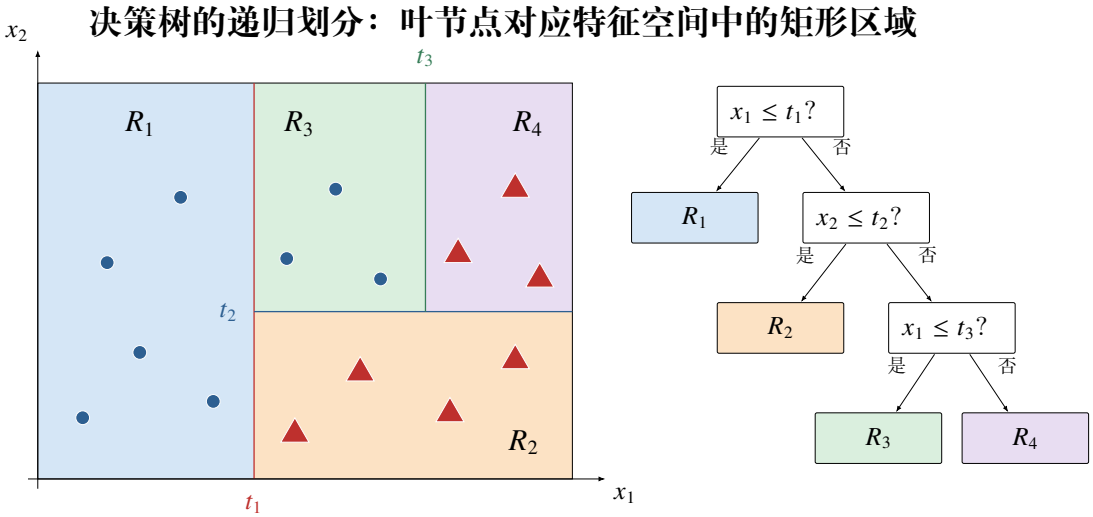
- 内部节点：表示一个特征、属性或判断条件；
- 叶节点：表示最终的类别或预测结果。

决策树算法

决策树算法是一种监督学习算法。它由给定划分准则，递归地选择特征及其划分条件，将特征空间划分为若干区域，形成树状结构，并利用叶节点对新样本进行分类或数值预测。

决策树 = 对特征空间做递归划分

每个内部节点使用规则 $x_j \le t$ 将当前区域分成两部分。



- 每次划分都与某个坐标轴平行；
- 递归划分后，每个叶节点对应一个矩形（或超矩形）区域

关键问题

选哪个特征？阈值放在哪里？何时停止？

分类叶节点与回归叶节点

分类树

预测叶节点多数类；类别比例可作为概率估计。

回归树

通常预测叶节点目标均值，得到分段常数函数。

局部模型

同一叶节点内的所有样本得到相同类别或相同回归值。

1 树的结构与预测

2 分类树
- 信息熵
- 信息增益
- Gini 指数

3 回归树

4 训练与解释

5 控制复杂度与评价

1 树的结构与预测

2 分类树
- 信息熵
- 信息增益
- Gini 指数

3 回归树

4 训练与解释

5 控制复杂度与评价

信息熵（Shannon Entropy）（重点）

定义：对于包含 N 个训练样本的数据集

$$D = \{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\},$$

假设共有 K 个类别，第 k 类样本所占**比例为** p_k，满足 $\sum_{k=1}^{K} p_k = 1$。
数据集 D 的**信息熵定义为**

$$\boxed{H(D) = -\sum_{k=1}^{K} p_k \log_2 p_k} \tag{1}$$

（约定 $0 \log_2 0 = 0$）。

信息熵衡量数据集类别分布的**不确定性**。
熵越大，类别分布越均匀，不确定性越高；熵越小，数据集越纯。
所有样本属于同一类别时，$H(D) = 0$。

例 1：计算投掷一枚均匀硬币的信息熵

解：硬币只有两种可能结果：

$$Y \in \{0, 1\}, \qquad K = 2.$$

正面朝上与反面朝上的概率相等：

$$p_1 = \frac{1}{2}, \qquad p_2 = \frac{1}{2}.$$

由信息熵的定义：

$$\begin{aligned} H(Y) &= -\sum_{k=1}^{2} p_k \log_2 p_k \\ &= -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = \boxed{1 \text{ bit}}. \end{aligned}$$

习题：计算投掷一枚非均匀硬币的信息熵

解：

$$Y \in \{0, 1\}, \qquad K = 2.$$

正面朝上与反面朝上的概率不相等：

$$p_1 = \frac{1}{4}, \qquad p_2 = \frac{3}{4}.$$

$$H(Y) = ?$$

结论:

1. 概率分布越平均，信息熵越大;
2. 所有概率均等时，信息熵达到最大值。

示例：计算投掷一枚骰子的信息熵

例 2：求投掷一枚均匀六面骰子的信息熵。

解：骰子有六种可能结果：

$$Y \in \{1, 2, 3, 4, 5, 6\}, \qquad K = 6.$$

每面的出现概率相等：$p_k = \frac{1}{6}, \qquad k = 1, \ldots, 6.$
根据信息熵的定义：

$$H(Y) = -\sum_{k=1}^{6} p_k \log_2 p_k = -6 \left(\frac{1}{6} \log_2 \frac{1}{6} \right)$$

$$= \log_2 6 \approx \boxed{2.58 \text{ bit}}.$$

1. 概率均等情况下，存在的可能性越多，则信息熵越大。
2. 对于固定数量的可能结果，概率分布越均匀，信息熵越大；
   所有结果等概率时，信息熵达最大值：$H_{\max} = \log_2 K$。

1 树的结构与预测

2 分类树
- 信息熵
- 信息增益
- Gini 指数

3 回归树

4 训练与解释

5 控制复杂度与评价

信息增益（Information Gain）（重点）

定义： **信息增益**衡量数据集 D 按照某个特征 A 划分后，**类别不确定性减少的程度**。

设特征 A 将数据集 D 划分为 m 个不相交的子集 $D_1, \ldots, D_m$。

1. 划分后的加权平均信息熵：

$$H(D \mid A) = \sum_{j=1}^{m} \frac{|D_j|}{|D|} H(D_j). \tag{2}$$

2. 信息增益的**定义**：

$$\boxed{IG(D, A) = H(D) - H(D \mid A)} \tag{3}$$

$H(D)$：划分前数据集的信息熵；
$H(D \mid A)$：按照特征 A 划分后的条件熵；
$IG(D, A)$：划分前后信息熵的减少量。

信息增益（Information Gain）

3. 在决策树中的作用：

(1) 信息增益越大，说明划分后类别的不确定性减少得越多；

(2) ID3 决策树优先选择**信息增益最大**的特征：

$$\boxed{A^* = \arg\max_A IG(D, A)}$$

信息熵计算：学生考试结果预测

例 3：某班有 6 名学生，根据是否完成作业，预测学生是否通过考试。数据如下：

学生	是否完成作业	是否通过考试
1	是	是
2	是	是
3	是	是
4	否	是
5	否	是
6	否	否

按“是否完成作业”将数据集 D 划分为两个子集 D_1 和 D_2。

(1) 计算子集的信息熵：

$$H(D_1) = -1 \log_2 1 = 0,$$

$$H(D_2) = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} \approx 0.918.$$

信息熵计算：学生考试结果预测

学生	是否完成作业	是否通过考试
1	是	是
2	是	是
3	是	是
4	否	是
5	否	是
6	否	否

（2）计算划分后的加权平均信息熵：

$$H(D_1, D_2) = \frac{|D_1|}{|D|} H(D_1) + \frac{|D_2|}{|D|} H(D_2)$$
$$= \frac{3}{6} \times 0 + \frac{3}{6} \times 0.918 = \boxed{0.459 \text{ bit}}.$$

信息增益计算：投掷一枚骰子

例 4：投掷一枚均匀骰子，按照点数的奇偶性将结果划分为两个子集：

$$D_1 = \{1, 3, 5\}, \qquad D_2 = \{2, 4, 6\}.$$

求划分后的加权平均信息熵及信息增益。

解： **（1）划分前的信息熵：**

$$H(D) = \log_2 6 \approx 2.58 \text{ bit}.$$

（2）计算子集的信息熵：

每个子集包含 3 种等概率结果，因此

$$H(D_1) = H(D_2) = -3\left(\frac{1}{3}\log_2\frac{1}{3}\right) = \log_2 3 \approx 1.58.$$

（3）划分后的加权平均信息熵：

$$\begin{aligned} H(D \mid A) &= \frac{|D_1|}{|D|}H(D_1) + \frac{|D_2|}{|D|}H(D_2) \\ &= \frac{3}{6} \times 1.58 + \frac{3}{6} \times 1.58 = \boxed{1.58 \text{ bit}}. \end{aligned}$$

信息增益率（Gain Ratio）

对于数据集 D 和划分特征 A，**定义信息增益率为**

$$\boxed{GR(D,A) = \frac{IG(D,A)}{IV(A)}} \tag{4}$$

$IG(D,A)$ 是 A 的信息增益，$IV(A)$ 称 A 的**固有值**（Intrinsic Value）：

$$IV(A) = -\sum_{j=1}^{m} \frac{|D_j|}{|D|} \log_2 \frac{|D_j|}{|D|}. \tag{5}$$

m 为 A 产生的非空子集数量，D_j 为第 j 个子集。

- $IV(A)$ 衡量划分后各子集大小分布的不确定性;
- 信息增益率越大，通常表示该划分越有效;
- C4.5 决策树采用信息增益率进行特征选择。

1 树的结构与预测

2 分类树
- 信息熵
- 信息增益
- Gini 指数

3 回归树

4 训练与解释

5 控制复杂度与评价

基尼指数（Gini Index）

基尼指数用于衡量数据集的**类别不纯度**。
对于含 K 个类的数据集 D，设第 k 类样本所占比例为 p_k，则基尼指数定义为

$$Gini(D) = \sum_{k=1}^{K} p_k(1-p_k) = 1 - \sum_{k=1}^{K} p_k^2 \tag{6}$$

划分后的基尼指数：
设特征 A 将数据集 D 划分为两个互不相交的子集 D_1, D_2，则

$$Gini(D \mid A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2) \tag{7}$$

$|D|$、$|D_1|$、$|D_2|$ 分别表示对应数据集的样本数量。

Gini 指数

物理意义与应用：

- 基尼指数越小，数据集的类别纯度越高。
- 当所有样本属于同一类别时，$Gini(D) = 0$。
- 类别分布越均匀，基尼指数越大。
- CART 分类树优先选择 **划分后基尼指数最小**的特征。

实践

Gini 与熵往往产生相近的树；Gini 是 scikit-learn 默认准则。

1 树的结构与预测

2 分类树

3 回归树

4 训练与解释

5 控制复杂度与评价

回归决策树：基本原理

分类树与回归树的区别

- 分类决策树：预测离散类别，例如材料的晶体结构类型。
- 回归决策树：预测连续数值，例如温度、热导率、能量等。

思想：不断划分特征空间，使每个子节点的目标值尽量接近。

对于一个候选划分，定义平方误差之和：

$$SSE = \sum_{i \in L} (y_i - \bar{y}_L)^2 + \sum_{i \in R} (y_i - \bar{y}_R)^2$$

- L, R 分别表示划分后的左、右子节点；
- y_i 为第 i 个样本的真实目标值；
- $\bar{y}_L, \bar{y}_R$ 为左右子节点目标值的均值。

划分准则

选择使左右子节点平方误差之和最小的特征与划分阈值。

回归决策树：具体例子（测得某材料在不同温度下的热导率）

T (K)	100	150	200	250	300	350
k (W/(m·K))	10	12	11	20	22	21

方案一：在 $T = 225\,\mathrm{K}$ 处分割 $\boxed{SSE_{\text{total}} = 4}$

$$L = \{10, 12, 11\}, \quad \bar{y}_L = 11, \qquad R = \{20, 22, 21\}, \quad \bar{y}_R = 21.$$

$$SSE_L = (10-11)^2 + (12-11)^2 + (11-11)^2 = 2,$$
$$SSE_R = (20-21)^2 + (22-21)^2 + (21-21)^2 = 2.$$

方案二：在 $T = 175\,\mathrm{K}$ 处分割 $\boxed{SSE_{\text{total}} = 79 > 4}$

$$\bar{y}_L = 11, \bar{y}_R = 18.5. \quad SSE_L = 2, SSE_R = 77.$$

因此，这两个方案中，$T = 225\,\mathrm{K}$ 的划分更优。

回归决策树：分段常数预测函数

设某叶节点包含 n 个样本，使用常数 c 作为该叶节点的预测值。
平方误差损失函数为：$S(c) = \sum_{i=1}^{n}(y_i - c)^2$.
对 c 求导：$\frac{dS}{dc} = -2\sum_{i=1}^{n}(y_i - c)$. 令导数为零，得：

$$\boxed{c = \frac{1}{n}\sum_{i=1}^{n} y_i = \bar{y}}$$

结论：对于平方误差损失，叶节点样本的均值是最优常数预测值。
例如，采用上一页的划分得到：

$$\boxed{\hat{k}(T) = \begin{cases} 11, & T \le 225\,\mathrm{K}, \\ 21, & T > 225\,\mathrm{K}. \end{cases}}$$

因此，回归决策树得到的是一个**分段常数预测函数**。

回归决策树：模型评价

1. 防止过拟合

若不限制划分，回归树可能不断生长，···

- `max_depth`：限制决策树的最大深度；
- `min_samples_leaf`：限制叶节点的最小样本数；
- 可使用交叉验证选择合适的模型复杂度。

2. 常用回归评价指标

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|; \quad RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

回归决策树：总结

总结

1. 分类树预测类别，回归树预测连续数值；
2. 回归树通过最小化子节点的平方误差选择划分；
3. 叶节点采用均值预测，生成分段常数函数；
4. 回归树能拟合非线性关系，但容易过拟合，且通常不具备外推能力。

1 树的结构与预测

2 分类树

3 回归树

4 训练与解释

5 控制复杂度与评价

scikit-learn 分类树

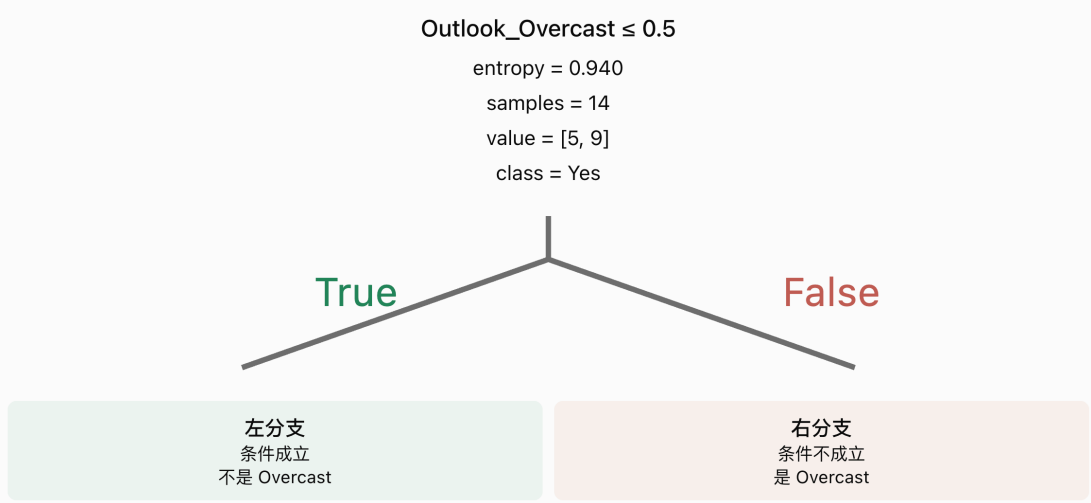
```
tree = DecisionTreeClassifier(
    max_depth=3,
    random_state=2)
tree.fit(X_train, y_train)
prediction = tree.predict(X_test)
probability = tree.predict_proba(X_test)
```

树模型通常不需标准化，但训练/测试划分和随机种子仍需明确记录。

怎样阅读一幅树图？

每个节点通常包含：

- 划分条件：如 Outlook_Overcast ≤ 0.5；
- impurity：Gini 或 entropy；
- samples：到达该节点的样本数；
  - value：各类别的样本计数或比例；
  - class：当前多数类。



沿某一样本满足的分支向下，即可解释其预测路径。

决策树的优势

- 规则直观，预测路径可以逐样本解释；
- 能表达非线性和特征交互；
- 对单调变换不敏感，无需特征标准化；
- 分类与回归都可使用；
- 训练和预测速度较快。

决策树的局限

- 深树容易过拟合，对数据扰动敏感；
- 回归树不能自然外推到训练目标范围之外；
- 叶节点样本少时，概率估计不稳定。

1 树的结构与预测

2 分类树

3 回归树

4 训练与解释

5 控制复杂度与评价

预剪枝：在建树时限制复杂度

- `max_depth`：最大深度；
- `min_samples_split`：继续划分所需最少样本；
- `min_samples_leaf`：叶节点最少样本；
- `max_leaf_nodes`：最大叶节点数。

限制越强，模型越简单：方差降低，但偏差可能增大。

后剪枝：代价复杂度剪枝

$$R_\alpha(T) = R(T) + \alpha|T|$$

$R(T)$ 是经验误差，$|T|$ 表示叶节点数量。

- $\alpha = 0$：倾向保留复杂树；
- α 增大：更强地惩罚叶节点数量；
- scikit-learn 参数为 `ccp_alpha`。

选择树的复杂度

1. 先留出独立测试集；
2. 只在训练集内部交叉验证；
3. 搜索深度、最小叶节点样本数等；
4. 确定评价指标；
5. 锁定模型后只评价一次测试集。

本节小结

- 树通过轴对齐问题递归划分特征空间；
- Gini、熵或平方误差决定当前最佳切分；
- 可视化路径使树易于解释；
- 深树容易过拟合，复杂度必须通过训练集内部验证选择。