机器学习

4. 聚类

黄刚

成都理工大学物理学院

2026 年 11 月 5 日



1. k-均值聚类
2. 凝聚聚类
3. DBSCAN
4. 聚类算法的评估

本节目标

- **重点**：K-Means、**凝聚聚类和 DBSCAN 的基本思想和特点**。

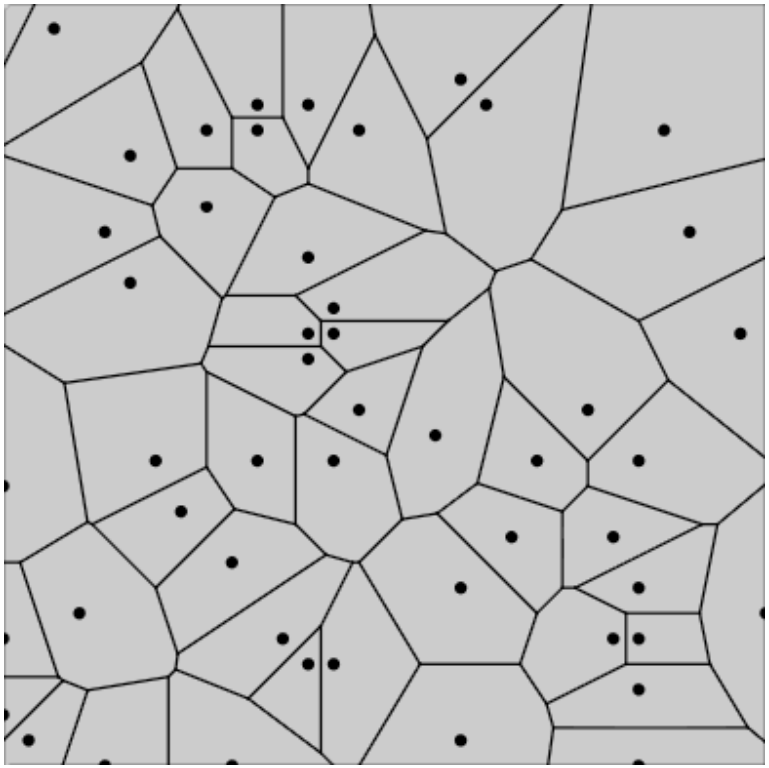
监督学习与无监督学习

	监督学习	无监督学习
输入	特征 X 与标签 y	特征 X
问题	预测性质或类别	描述相似性、结构、分布
例子	材料带隙预测	按描述符探索材料分组
评价	独立样本预测误差	内部结构、稳定性

1. k-均值聚类
2. 凝聚聚类
3. DBSCAN
4. 聚类算法的评估

k-均值聚类：问题

- 目标：把 n 个点划分到 K 个类中，使每个点离它最近的均值 (聚类中心) 对应的类；
- 等价问题：把数据空间划分为 Voronoi 元胞。



k-均值聚类: 数学描述

- 观测集: $(X_1, \cdots, X_n)$ (X_i 为 d 维矢量);
- 问题: 把 n 个观测点划分到 k 个集合中, 使得簇内平方和

$$\sum_{i}^{K} \sum_{x \in C_i} \|x - \mu_i\|^2$$

最小 (C_i 为第 i 簇中观测点的集合, μ_i 为该簇的均值):

$$\min_{C_1,\ldots,C_k} \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \mu_j\|^2, \quad \mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i.$$

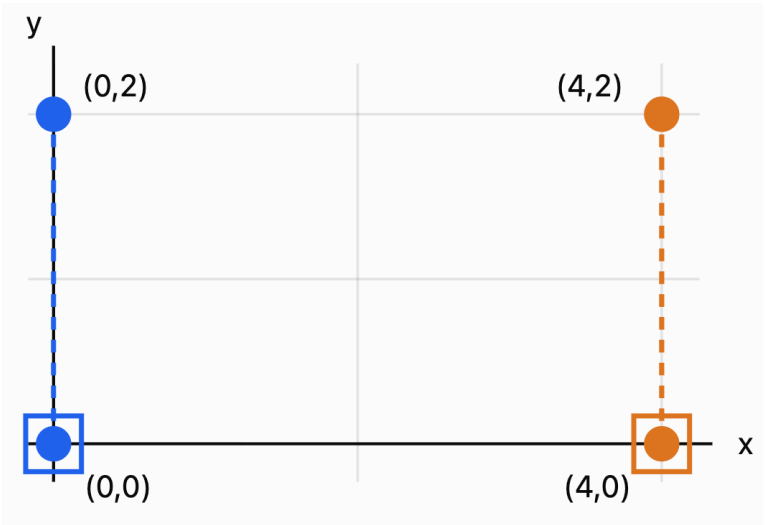
K-Means 算法

1. 初始化 k 个中心：$\mu_1, \cdots, \mu_k$
2. 分配：$c_i = \arg\min_j \|x_i - \mu_j\|^2$。
3. 更新：$\mu_j = \text{mean}\{x_i : c_i = j\}$。
4. 重复直到中心变化足够小或达到迭代上限。

例 1：一次更新

样本：$(0,0),(0,2),(4,0),(4,2)$。**初始中心**：$(0,0),(4,0)$。

1. 每个点离哪个中心更近？
2. 两个新中心分别是什么？
3. 更新前后的簇内平方和各是多少？



K-Means 的几何偏好

- 只能找到近似球状且尺度接近的簇；
- 狭长簇、月牙形、大小悬殊的簇可能被错误拆分或合并；
- 平方距离让远离中心的异常点影响较大；
- 算法总会按给定 k 给出分组。

1 k-均值聚类

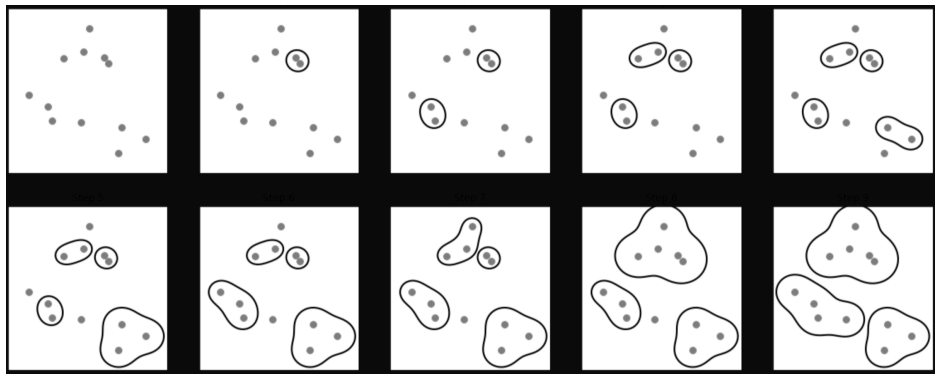
2 凝聚聚类

3 DBSCAN

4 聚类算法的评估

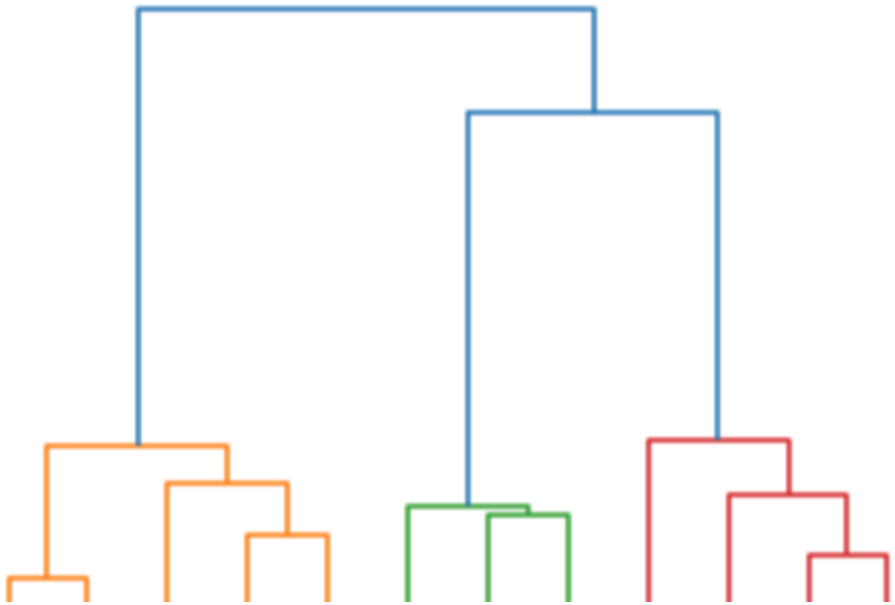
凝聚聚类 (agglomerative clustering)

- 含义：指许多基于相同原则构建的聚类算法：首先声明每个点是自己的簇，然后合并两个最相似的簇，迭代，直到满足停止准则。
- 停止准则：簇个数；链接 (linkage) 准则 (ward, average, complete).



凝聚聚类 (agglomerative clustering)

- 层次聚类 (hierarchical clustering)：每个点东一个单点簇变为属于最终的某个簇。每个中间步骤都提供了数据的一种聚类 (簇的个数不同)；
- 可以同时查看所有的聚类；
- 树状图 (dendrogram)：将层次聚类可视化的工具，可以处理多维数据集。



1 k-均值聚类

2 凝聚聚类

3 DBSCAN

4 聚类算法的评估

DBSCAN

- 含义：带噪声的基于密度的空间聚类 (DBSCAN, density-based spatial clustering of applications with noise)：识别特征空间中密级 (dense) 区，把这些区域的点聚集在一起；
- 思想：簇形成数据的密集区域，并由相对较空的区域分开；
- 优点：不需要先验设置簇的个数；可以划分有复杂形状的簇，可以找出不属于任何簇的点。
- 缺点：比 k-means 和凝聚聚类稍慢。

DBSCAN 的算法

- **核心样本**：在距离一个给定数据点 d_s 的距离内至少有 M 个数据点，那么这个数据点就是核心样本。
- 将彼此距离小于 d_s 的核心样本归为同一个簇。
- 最后，会得到三种类型的点：核心样本、与核心的距离在 d_s 之内的点（boudary point）、噪声。

1. k-均值聚类
2. 凝聚聚类
3. DBSCAN
4. 聚类算法的评估

有真实值时评估聚类

- 调整 rand 指数 (ARI，Adjusted Rand index)
- 归一化互信息 (NMI, Normalized Mutual Information)

没有真实值时评估聚类

- 应用聚类时，通常没有真实值来比较结果。
- 轮廓系数 (silhouette coeffient)：用于计算一个簇的紧致度，其值越大越好，最高为 1.

补充：轮廓系数

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

- $a(i)$：到同簇其他点的平均距离。
- $b(i)$：到各其他簇的平均距离的最小值。
- 接近 1 表示相对分离良好，接近 0 表示边界模糊，负值提示可能归错簇。
- 适用于至少 2 簇且簇数小于样本数的情形；单点簇通常约定为 0。
- 该指标偏好紧凑分离的结构，对非凸簇可能误导。

聚类方法小节（k 均值、凝聚聚类、DBSCAN）

- 聚类的应用和评估：定性的过程，常用于数据分析的探索阶段。
- 聚类算法可以控制聚类的粒度 (granularity)：簇的数量，距离 d_s.
- 三种算法都可以用于现实世界的数据集，都可以聚集成多个类；
- 各有优点：k 均值用簇的平均值表示簇；DBSCAN 可以检测到没有分配任何簇的噪声点，可以自动判断簇数量，允许簇具有复杂形状，会生成大小差别很大的簇；凝聚聚类可以提供数据可能划分的层次结构，可由树状图查看。