1 主成分分析的含义

2 算法

3 总结、作业

4 作业

PCA 要解决什么问题？

每个样本有很多变量，其中一些信息可能重复。

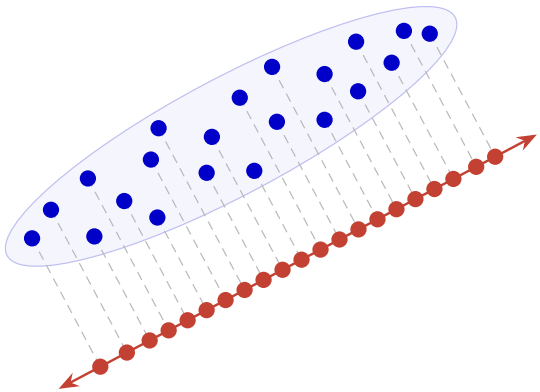
- 例如：身高与腿长通常相关，都包含一部分“体型大小”的信息。
- PCA 将原变量组合成少数几个新变量，称为主成分。
- 目标：减少变量，同时尽量保留样本之间的差异。

$$\underbrace{X}_{n\text{ 个样本，}d\text{ 个变量}} \longrightarrow \underbrace{Z}_{n\text{ 个样本，}k\text{ 个新变量}}, \qquad k < d$$

基本思想：找数据最分散的方向

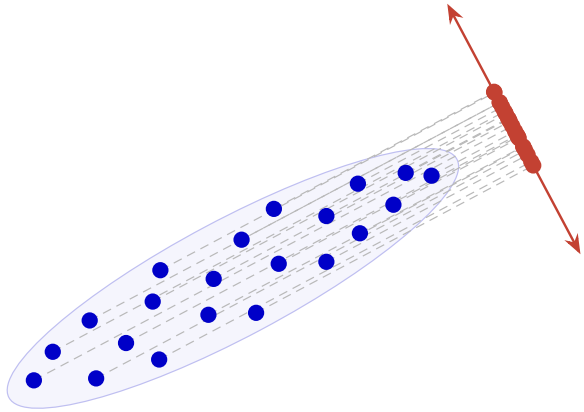
把一团数据点投影到直线上，

- 沿数据伸展的方向投影，点与点之间的差异较大；
- 沿数据很窄的方向投影，许多点会挤在一起。



(a) 向长轴方向投影

点分布较宽，方差较大



(b) 向短轴方向投影

点挤在一起，方差较小

主成分

PCA 尽量保留差异：投影后的方差最大

投影后的方差越大，保留的变化越多。

第一主成分：方差最大的方向;

第二主成分：与第一主成分垂直，在剩余方向中方差最大;

……

1 主成分分析的含义

2 算法

3 总结、作业

4 作业

第一步：把数据中心移到原点

数据矩阵 $X \in \mathbb{R}^{n\times d}$：每行一个样本，每列一个变量。

$$\mu_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \qquad \boxed{(X_c)_{ij} = x_{ij} - \mu_j}$$

（中心化），现在每一列的平均值都是零。

是否还要标准化？

当变量的数值的量级差异很大，且希望各变量具有相同的初始方差时，可使用

$$\widetilde{x}_{ij} = \frac{x_{ij} - \mu_j}{s_j}$$

s_j 是第 j 列的样本标准差。常数列应先移除。

以下用中心化矩阵 X_c；若标准化，用 $\widetilde{X}$ 代替。

第二步：用方差写出目标

协方差矩阵：

$$C = \frac{1}{n-1} X_c^\top X_c \in \mathbb{R}^{d \times d}$$

取单位向量 w 表示一个方向，投影后的新变量为 $z = X_c w$。

$$\mathrm{Var}(z) = \frac{z^\top z}{n-1} = w^\top C w$$

由前面的讨论，第一主成分方向满足

$$\boxed{\max_{\|w\|=1} \; w^\top C w}$$

限制 $\|w\| = 1$，才能只比较方向，避免靠放大向量来放大方差。

第三步：求主成分方向

上一个优化问题的解，来自协方差矩阵的特征向量：

$$Cw_i = \lambda_i w_i, \qquad \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0$$

- w_i：第 i 个主成分方向，取单位长度、彼此正交。
- λ_i：数据在该方向上的方差。

(第四步：完成降维)
保留前 k 个方向，把每个样本投影到这些方向上：

$$W_k = [w_1, \ldots, w_k], \qquad \boxed{Z = X_c W_k \in \mathbb{R}^{n \times k}}$$

方向 w_i 给出原变量的组合权重；Z 给出每个样本的新坐标。

例 1

三个二维样本：$(1,1),(2,2),(3,3)$，均值为 $(2,2)$。

$$X_c = \begin{pmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{pmatrix}, \qquad C = \frac{X_c^\top X_c}{2} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

$$\lambda_1 = 2, \quad w_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}; \qquad \lambda_2 = 0$$

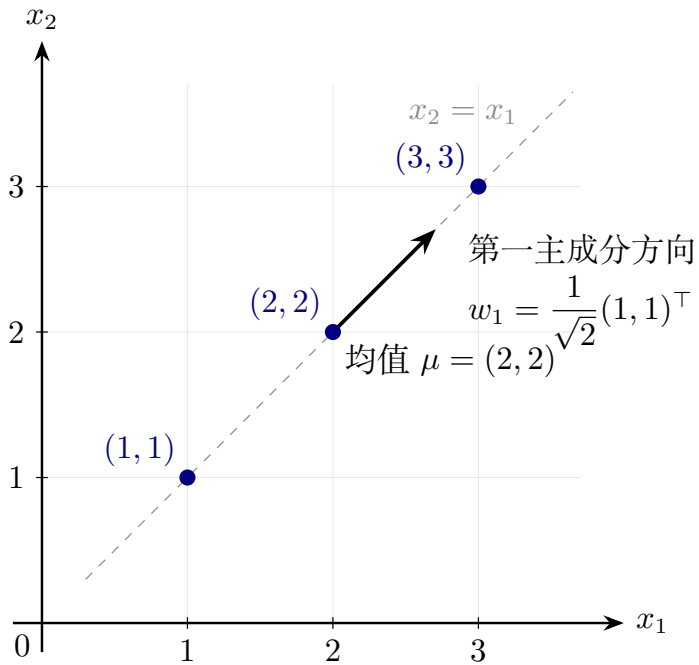
保留第一主成分：

$$Z = X_c w_1 = \begin{pmatrix} -\sqrt{2} \\ 0 \\ \sqrt{2} \end{pmatrix}$$

例 1

三个二维样本：$(1,1),(2,2),(3,3)$，均值为 $(2,2)$。

保留第一主成分 (降维) 后，数据可表示为 $Z = X_c w_1 = \begin{pmatrix} -\sqrt{2} \\ 0 \\ \sqrt{2} \end{pmatrix}$



箭头从均值出发，表示单位主成分方向

三个点都位于该方向所在的直线上

保留几个主成分？

前 k 个主成分的累计解释方差比例为

$$\boxed{r_k = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_d}}$$

例如：$\lambda_1 = 8, \lambda_2 = 1.5, \lambda_3 = 0.5$。

$$r_1 = 80\%, \qquad r_2 = 95\%, \qquad r_3 = 100\%$$

- 若希望保留至少 95% 的总方差，选择 $k = 2$。
- 若所有特征值都是零，数据没有变化，上述比例无定义。

1 主成分分析的含义

2 算法

3 总结、作业

4 作业

PCA 的流程

1. 每列减均值，按需要再除以标准差。
2. 计算协方差矩阵 C。
3. 求特征值、特征向量，按特征值从大到小排序。
4. 选择 k，计算 $Z = X_c W_k$。

利用新坐标可以近似重建原数据：

$$\widehat{X} = ZW_k^\top + \mathbf{1}\mu^\top$$

若做过标准化，还需先乘回各列标准差，再加均值。

PCA 在所有 k 维正交线性投影中，使重建的平方误差最小。

1 主成分分析的含义

2 算法

3 总结、作业

4 作业

作业 1

阅读 Andreas C. Müller 和 Sarah Guido《*Python* 机器学习基础教程》PCA 部分，理解其含义、应用.

(5 分) 作业 2：三维数据的 PCA

给定四个三维样本：

$$x_1 = (3, 3, 1), \quad x_2 = (1, 1, 1), \quad x_3 = (2, 2, 2), \quad x_4 = (2, 2, 0).$$

仅做中心化，不做标准化。采用样本协方差：

$$C = \frac{1}{n-1} X_c^\top X_c, \qquad n = 4.$$

1. 求均值向量 μ 和中心化矩阵 X_c。
2. 计算 3×3 协方差矩阵 C。
3. 求各主成分的方向及对应的方差。
4. 若至少保留 90% 的总方差，应保留几个主成分？
5. 求保留这些主成分后，各样本的新坐标。