

机器学习

1. k 近邻算法

黄刚

成都理工大学物理学院

2026 年 9 月 29 日



- ① 基础回顾
- ② k 近邻算法
- ③ 扩展

- ① 基础回顾
- ② k 近邻算法
- ③ 扩展

1.1 监督学习 (Supervised Learning)

基本思想

训练数据中同时包含特征 (**features**) 和对应的标签 (**labels**), 算法学习从输入到目标的映射关系:

$$X \longrightarrow y$$

分类 (Classification)

预测离散类别。

- 垃圾邮件 / 正常邮件
- 猫 / 狗

$$y_i = \text{类别标签}$$

回归 (Regression)

预测连续数值。

- 房价预测
- 材料性质预测

$$y_i = \text{连续数值}$$

对于 n 个样本、每个样本有 d 个特征：

$$X \in \mathbb{R}^{n \times d}, \quad y = (y_1, y_2, \dots, y_n)^T.$$

关键点： 监督学习的训练数据必须给出目标变量 y 的已知值。

1.2 过拟合与欠拟合：基本概念

模型的目标：可归纳（generalizable）

如果一个模型不仅在训练数据上表现好，而且能对未曾见过的新数据作出准确预测，则称这个模型具有较好的泛化能力。

过拟合（Overfitting）

模型过于复杂，几乎记住了训练集。

- 训练误差很小
 - 测试误差较大
 - 对新数据预测变差
- 模型复杂度过高

欠拟合（Underfitting）

模型过于简单，连训练数据中的主要规律也没有学到。

- 训练误差较大
 - 测试误差也较大
 - 模型表达能力不足
- 模型复杂度过低

1.2 举例：用曲线拟合数据

假设我们要根据输入 x 预测输出 y ，训练数据来自某个带噪声的真实规律。

欠拟合

用一条过于简单的直线拟合弯曲数据。

$$y = ax + b$$

- 模型太简单
- 训练集拟合差
- 新数据预测也差

合适拟合

用复杂度适中的曲线描述主要趋势。

$$y = f(x)$$

- 抓住主要规律
- 不学随机噪声
- 泛化能力较好

过拟合

用非常高阶的曲线穿过几乎所有训练点。

$$y = \sum_{k=0}^m a_k x^k, m \gg 1$$

- 训练集误差小
- 新数据预测差

小结

机器学习追求对新数据的准确预测。

合适的模型复杂度通常位于欠拟合和过拟合之间。

- ① 基础回顾
- ② k 近邻算法
- ③ 扩展

KNN 算法 (k-Nearest Neighbors)

基本思想

KNN (**k-Nearest Neighbors**, **k** 近邻) 是一种 监督学习 算法。它不需要显式地学习一个复杂的模型, 而是直接保存训练数据。

对于一个新的待预测样本, KNN 的基本步骤是:

- ① 计算新样本与所有训练样本之间的**距离**;
- ② 找到距离最近的 k 个训练样本, 即 k 个**最近邻**;
- ③ 根据这些邻居的标签, 对新样本进行预测。

核心思想

相似的样本通常具有相似的标签

因此, 判断新样本属于哪一类, 可以看它的 **邻居是谁**。

KNN 分类：邻居投票

假设训练集中有两类样本：

类别 A： ●

类别 B： △

现在给定一个新的未知样本 x 。

当 $k = 1$

只寻找距离 x 最近的一个训练样本。

如果最近的样本属于类别 A，则

$$x \rightarrow A$$

方法简单，但易受到噪声影响。

当 $k > 1$

寻找距离 x 最近的 k 个样本，然后进行多数投票 (**majority voting**)。

例如 $k = 5$ ：有 3 个样本属于类别 A，2 个样本属于类别 B。则预测结果为

$$x \rightarrow A$$

KNN 的两个关键问题

如何定义距离？

如何选择 k ？

- ① 基础回顾
- ② k 近邻算法
- ③ 扩展

距离度量：什么叫“相似”？

对于两个样本 $\mathbf{x} = (x_1, \dots, x_d)$ 和 $\mathbf{z} = (z_1, \dots, z_d)$ ：

欧氏距离 ($p = 2$)

$$d_2(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^d (x_j - z_j)^2}$$

适合连续、尺度相近的特征。

曼哈顿距离 ($p = 1$)

$$d_1(\mathbf{x}, \mathbf{z}) = \sum_{j=1}^d |x_j - z_j|$$

对单个特征的极端差异不敏感。

Minkowski 距离

$$d_p(\mathbf{x}, \mathbf{z}) = \left(\sum_{j=1}^d |x_j - z_j|^p \right)^{1/p}$$

特征缩放

假设用两个特征判断动物是否为鱼：

体长：0 ~ 3000 cm, 水中活动比例：0 ~ 1.

问题

直接计算欧氏距离时，体长的数值范围远大于活动比例，距离几乎完全由体长决定。

标准化

$$x'_j = \frac{x_j - \mu_j}{\sigma_j}$$

常用工具：StandardScaler

最小--最大缩放

$$x'_j = \frac{x_j - x_j^{\min}}{x_j^{\max} - x_j^{\min}}$$

常用工具：MinMaxScaler

缩放参数只能从训练数据估计，否则会发生数据泄漏。

KNN 分类：从多数投票到距离加权

对新样本 $\mathbf{x}$ ，记它的 k 个邻居集合为 $N_k(\mathbf{x})$ 。

多数投票

$$\hat{y}(\mathbf{x}) = \arg \max_c \sum_{i \in N_k(\mathbf{x})} 1(y_i = c)$$

每个邻居拥有相同的投票权。

距离加权投票

$$\hat{y}(\mathbf{x}) = \arg \max_c \sum_{i \in N_k(\mathbf{x})} w_i 1(y_i = c), \quad w_i = \frac{1}{d(\mathbf{x}, \mathbf{x}_i) + \varepsilon}$$

距离越近的样本拥有越大的影响。

尽量避免平票。

k 控制模型复杂度

k 较小

- 决策边界曲折
- 对局部噪声敏感
- 偏差低、方差高
- 容易过拟合

k 较大

- 决策边界平滑
- 局部结构被平均
- 偏差高、方差低
- 可能欠拟合

不能只凭经验选 k ，也不能用测试集反复试验；应在训练数据内部使用交叉验证选择 k 。

如何选择 k : 交叉验证与 Pipeline

- ① 留出独立测试集，只用于最后一次评价；
- ② 在训练集内部进行 K 折交叉验证；
- ③ 同时比较邻居数、距离权重和距离度量；
- ④ 用最优设置重新拟合全部训练数据；
- ⑤ 最后在测试集上报告泛化性能。

搜索空间

$$k \in \{1, 3, 5, \dots, 19\}, \quad p \in \{1, 2\}, \\ \text{weights} \in \{\text{uniform}, \text{distance}\}.$$

防止数据泄漏

将 StandardScaler 和 KNN 放入同一个 Pipeline，使缩放过程在每个交叉验证训练折内重新拟合。

KNN 回归：邻居目标值的局部平均

分类预测类别，回归预测连续数值。

等权平均

$$\hat{y}(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} y_i$$

每个邻居贡献相同。

距离加权平均

$$\hat{y}(\mathbf{x}) = \frac{\sum_i w_i y_i}{\sum_i w_i},$$
$$w_i = \frac{1}{d_i + \varepsilon}.$$

更近的邻居贡献更大。

特点

KNN 回归是一种局部平滑方法： k 小则曲线更灵活， k 大则曲线更平滑；通常不能外推到训练数据范围之外。

如何评价 KNN 的预测结果？

分类任务

- 准确率 (Accuracy)
- 混淆矩阵
- Precision、Recall
- F1 分数

类别不平衡时 (如 99% 都是负类, 1% 是正类), 不能只看准确率。

回归任务

- MAE: 平均绝对误差
- RMSE: 均方根误差
- R^2 : 决定系数

应结合误差大小和科学问题的尺度解释。

报告交叉验证结果时, 需要同时给出均值与波动, 不能只报告最高分。(见代码练习)

分类结果：混淆矩阵

对于二分类问题，可以用下面的混淆矩阵表示预测结果：

	预测为正类	预测为负类
实际为正类	TP	FN
实际为负类	FP	TN

- TP (True Positive): 实际为正，预测也为正；
- TN (True Negative): 实际为负，预测也为负；
- FP (False Positive): 实际为负，但错误预测为正；
- FN (False Negative): 实际为正，但错误预测为负。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}.$$

分类模型的评价指标

- **准确度 (Accuracy)**: 表示所有样本中, 预测正确的比例。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **召回率 (Recall)**: 所有真正的正类样本中, 被成功识别出来的比例。

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1 分数 (F1-score)** $F_1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$
综合衡量 Precision 和 Recall, 特别适合类别不平衡问题。

Accuracy: 预测有多准 Recall: 正类找回多少 F1: 综合两者

计算代价与高维问题

设训练样本数为 n 、特征数为 d 。

计算与存储

- 几乎无显式训练过程
- 保存训练数据: $O(nd)$
- 暴力预测每个新样本:
 $O(nd)$
- 大数据集上预测可能很慢

维数灾难

- 高维空间越来越稀疏
- 最近邻与远邻的距离趋于接近
- 通常需要特征选择或降维

KNN 适合什么问题？

优点

- 思想直观、实现简单
- 可用于分类和回归
- 不需要假设全局函数形式
- 能描述非线性决策边界

局限

- 对尺度、噪声和无关特征敏感
- 高维或大样本时效率下降
- 缺失值需要先处理
- 回归通常缺乏外推能力

适用场景

样本规模小、维度不高、局部相似性具有科学意义，且能定义合理距离的任务。

kNN 算法的流程

- ① 明确任务：分类还是回归，并确定评价指标；
- ② 划分训练集与测试集；
- ③ 完成缺失值处理、特征缩放；
- ④ 在训练集内部交叉验证，选择 k 、权重与距离；
- ⑤ 检查训练与验证表现，判断过拟合或欠拟合；
- ⑥ 锁定模型后，在测试集上进行一次最终评价；
- ⑦ 报告指标、波动、数据划分方式和模型设置。

核心

测试集不参与模型选择

+

预处理不接触验证数据