# 机器学习

## 2. 线性模型

黄刚

成都理工大学物理学院

2026 年 10 月 15 日



1. 线性回归
2. 正则化回归
3. 线性分类
4. 模型的评价
5. 附录

# 学习内容

## 回归

最小二乘 → 指标 → Ridge/Lasso

## 分类

线性得分 → Logistic/Linear SVM

## 可靠评价

从训练集学参数；交叉验证选超参数；测试集做最终评价.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

# 一元线性回归

$$\hat{y} = w_0 + w_1 x$$

- $w_0$ 是截距，$w_1$ 是斜率；
- 残差 $e_i = y_i - \hat{y}_i$.

# 最小二乘法 (Ordinary Least Squares)

$$\min_{\boldsymbol{w}} \|\boldsymbol{y} - X\boldsymbol{w}\|_2^2 \qquad \hat{\boldsymbol{w}} = (X^T X)^{-1} X^T \boldsymbol{y}$$

**数值计算**

使用 QR/SVD（如 `np.linalg.lstsq`）或成熟实现.

# 建模流程

1. 划分训练集和测试集；
2. 在训练集 `fit(X,y)`；
3. 在测试集 `predict(X)`；
4. 评价误差并检查残差图.

## 模型参数

`intercept_` 对应 $w_0$，`coef_` 对应各个 $w_j$.

# 回归指标

c

| 指标 | 定义 | 解释 |
| --- | --- | --- |
| MAE | $n^{-1}\sum\lvert y_i-\hat{y}_i\rvert$ | 原单位、直观 |
| RMSE | $\sqrt{n^{-1}\sum(y_i-\hat{y}_i)^2}$ | 更惩罚大误差 |
| $R^2$ | $1-SS_{res}/SS_{tot}$ | 相对均值基准的改进 |

**注意**

测试集 $R^2$ 可小于 0.

# 多元线性回归

$$\hat{y} = w_0 + \sum_{j=1}^{p} w_j x_j$$

- 系数是“其他特征固定时”的线性关联.
- 量纲不同，不能直接比较系数.
- 共线性使系数不稳定.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

# 为什么需要正则化？

普通最小二乘：尽量让训练误差小；
正则化最小二乘：在训练误差尽量小的同时，避免模型对数据的偶然变化过度敏感.

**训练集**

特征多时容易追随噪声，训练误差很低.

**新数据**

大系数对扰动敏感，测试误差上升.

允许少量偏差，换取更低方差和更稳定的泛化.

# Ridge 回归：L2 惩罚

$$\min_{w} \frac{1}{n}\|y - Xw\|_2^2 + \alpha\|w\|_2^2$$

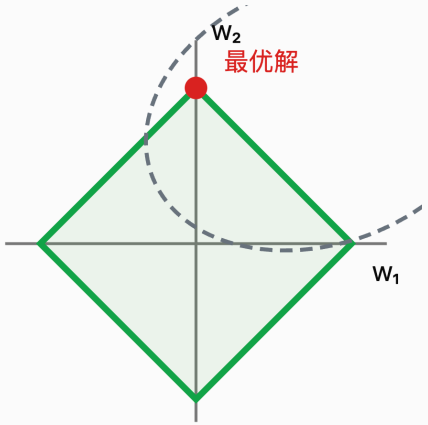
岭回归（Ridge Regression）的核心思想：在线性回归的基础上，对过大的回归系数施加惩罚，从而减少过拟合，提高模型的泛化能力.

- 它增加了回归系数的**平方和**惩罚项;
- $\alpha$ 越大，收缩越强;
- 通常保留全部特征但降低系数幅度.

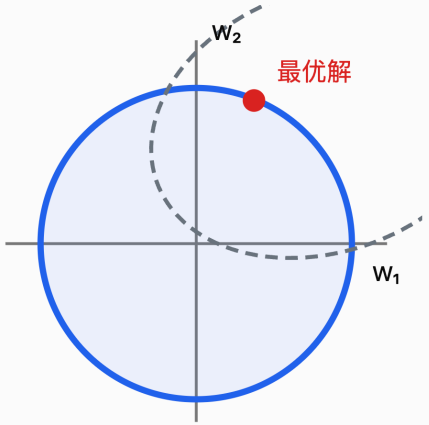
# Lasso 回归：L1 惩罚

$$\min_{w} \frac{1}{n}\|y - Xw\|_2^2 + \alpha\|w\|_1$$

- 它增加了回归系数的**绝对值之和**惩罚项;
- 部分系数精确变为 0，可做嵌入式特征选择;
- 相关特征间的选择可能不稳定;
- $\alpha$ 太大将欠拟合.




L1：菱形约束区域




L2：圆形约束区域

# OLS、Ridge、Lasso

| | OLS | Ridge | Lasso |
|---|---|---|---|
| 惩罚 | 无 | $\sum w_j^2$ | $\sum \lvert w_j \rvert$ |
| 系数 | 可很大 | 整体收缩 | 可为 0 |
| 相关特征 | 不稳定 | 较稳定 | 可能任选其一 |
| 用途 | 基本方法 | 稳定预测 | 稀疏选择 |

## 共同要求

先标准化；$\alpha$ 在训练集内部交叉验证选择.

# 交叉验证（Cross-Validation）的步骤




1. **划分数据**：将训练集随机划分为 5 个大小相近的子集 $D_1, \ldots, D_5$.
2. **轮流训练与验证**：共进行 5 轮.
3. **计算验证分数**：第 $k$ 轮得到验证分数 $S_k$，例如决定系数 $R^2$.
4. **计算平均性能**：将 5 轮验证分数取平均：

$$S_{\mathrm{CV}} = \frac{1}{5} \sum_{k=1}^{5} S_k$$

5. **选择模型**：对不同超参数（如 Ridge 的 $\alpha$）重复上述过程，选择平均验证性能最好的参数.

# Pipeline 防止数据泄漏

```
pipe = Pipeline([
  ("scale", StandardScaler()),
  ("model", Ridge())])
search = GridSearchCV(
  pipe, {"model__alpha": alphas}, cv=5)
```

**全数据先标准化**会把验证折信息泄漏到训练过程.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

# 线性分类器：如何将样本分为两类？(1)

**基本思想**：
根据样本的特征，构造一个线性函数，利用函数值的正负判断样本属于哪一类.

设样本有 $p$ 个特征：

$$\mathbf{x} = (x_1, x_2, \ldots, x_p)^T.$$

线性分类器首先计算一个**分类得分**：

$$z = \mathbf{w}^T\mathbf{x} + b = \sum_{j=1}^{p} w_j x_j + b$$

- $\mathbf{w}$：权重向量，决定各特征的贡献；
- $b$：偏置（截距），决定分类边界的位置；
- $z$：分类得分，其正负决定预测类别.

# 线性分类器：如何将样本分为两类？(2)

**分类规则**：

$$\hat{y} = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0. \end{cases}$$

## 什么是决策边界？

满足 $\mathbf{w}^T\mathbf{x} + b = 0$ 的点构成决策边界.
在二维空间中它是一条直线；在三维空间中它是一个平面；在更高维空间中它是一个超平面.

# 线性分类器：特征变换与分类能力 (1)

**问题**：如果两类样本无法用一条直线分开，该怎么办？

考虑二维特征 $\mathbf{x} = (x_1, x_2)$，普通线性分类器的决策边界为

$$w_1 x_1 + w_2 x_2 + b = 0,$$

它只能表示原始二维空间中的直线.

**解决思路：构造新的特征.**
例如，引入二次特征：

$$\phi(\mathbf{x}) = (x_1, x_2, x_1^2, x_2^2, x_1 x_2)^T.$$

在线性分类器中使用这些新特征：

$$\boxed{z = \mathbf{w}^T \phi(\mathbf{x}) + b}$$

展开后，决策边界变为

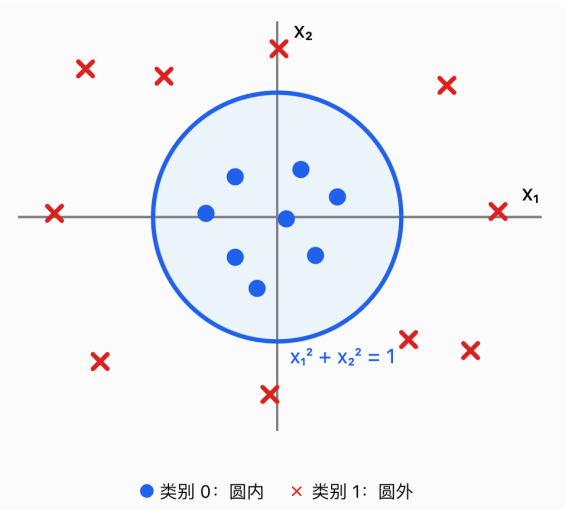
$$w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_2^2 + w_5 x_1 x_2 + b = 0.$$

# 线性分类器：特征变换与分类能力 (2)

**例：若 $z = x_1^2 + x_2^2 - 1$，则分类边界为**

$$\boxed{x_1^2 + x_2^2 = 1}$$

**即原始二维空间中的一个圆！**




## 核心结论

线性分类器在特征空间中使用超平面分类，但经过非线性特征变换后，在原始空间中可以形成非线性决策边界.

# 逻辑回归：基本原理

$$p(y=1|x)=\sigma(z)=\frac{1}{1+e^{-z}},\qquad \log\frac{p}{1-p}=w^Tx+b$$

**目标：求一个样本（数据点）属于一个特殊类别的条件概率.**

- $p(x)\in[0,1]$;
- **赔率** $\frac{p(x)}{1-p(x)}\in(0,\infty)$.
- **赔率的对数** $\log\frac{p(x)}{1-p(x)}\in(-\infty,\infty)$.

# 逻辑回归：学习、分类

**1. 如何学习模型参数？**

逻辑回归通过 Sigmoid 函数预测类别 1 的概率：

$$p_i = P(y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x}_i + b)}}.$$

通过最小化**对数损失（Log Loss）**学习参数：

$$L = -\frac{1}{N} \sum_{i=1}^{N} \left[ y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right].$$

**2. 如何将概率转换为类别？**

$$\hat{y}_i = \begin{cases} 1, & p_i \geq t, \\ 0, & p_i < t. \end{cases}$$

通常取 $t = 0.5$，但可根据漏检和误报代价作调整.

**注意**

逻辑回归不仅给出类别，还能预测类别概率.

# 逻辑回归：评价

**3. 如何评价模型？**

- **Accuracy、Precision、Recall**：评价给定阈值下的分类结果.
- **ROC-AUC**：评价模型区分正负样本的能力.
- **概率校准（Calibration）**：评价预测概率与实际发生频率是否一致.

**注意**

逻辑回归通过最小化对数损失学习模型参数，再利用 Sigmoid 函数预测样本属于正类的概率；分类阈值决定最终的分类结果；ROC-AUC 和概率校准分别评价模型的区分能力与概率可靠性.

# 正则化参数 $C$

**Ridge/Lasso 的 $\alpha$**

$\alpha$ 越大，正则化越强.

**Logistic/SVM 的 $C$**

$C$ 越小，正则化越强.

观察训练/验证表现与系数范数，不追求最大的训练准确率.

# L1 Logistic 与 Linear SVM

- L1 Logistic 产生稀疏系数.
- Linear SVM 用 hinge loss 强调间隔，默认只给决策分数.
- 二者均需标准化，均用 $C$ 控制正则化.
- 需要概率时，Logistic 更直接；SVM 需校准.

# 线性支持向量分类器：最大间隔原理

**基本思想**：对于二分类问题，寻找一个分类超平面，使两类样本之间的 分类间隔（Margin）最大.

设训练样本为 $(\mathbf{x}_i, y_i)$，$y_i \in \{-1, +1\}$.
线性分类器的决策函数为

$$f(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b, \qquad \hat{y} = \text{sign}(f(\mathbf{x})).$$

**分类超平面与间隔边界**：

$$\mathbf{w}^T\mathbf{x} + b = 0, \qquad \mathbf{w}^T\mathbf{x} + b = \pm 1.$$

两条间隔边界之间的距离为 $\text{Margin} = \frac{2}{\|\mathbf{w}\|_2}$.
因此，最大化分类间隔等价于求解

$$\min_{\mathbf{w},b} \quad \frac{1}{2}\|\mathbf{w}\|_2^2 \quad \text{s.t.} \qquad y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1.$$

## 支持向量（Support Vectors）

位于间隔边界上的训练样本称为支持向量. 它们决定了最优分类超平面的位置与方向.

# 线性支持向量分类器：软间隔与正则化

训练数据常不能完全线性分离，可允许部分样本进入分类间隔.

引入松弛变量 $\xi_i \geq 0$，得到软间隔 SVM：

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi}} \quad & \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{i=1}^{N}\xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \end{aligned}$$

上述问题等价于最小化

$$J(\mathbf{w}, b) = \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{i=1}^{N}\max(0, 1 - y_i f(\mathbf{x}_i))$$

$L_{\text{hinge}} = \max(0, 1 - y_i f(\mathbf{x}_i))$ **称为合页损失（Hinge Loss）**.

**正则化参数 $C$ 的作用：**

- $C$ 较大：更重视训练误差，对间隔违反施加强惩罚，可能过拟合.
- $C$ 较小：更重视分类间隔，允许更多间隔违反，可能欠拟合.

# 分类指标

- 混淆矩阵展示 TP、FP、TN、FN.
- Precision 与 Recall 对应不同错误代价.
- Balanced accuracy 适合类别不平衡.
- ROC-AUC 衡量排序能力.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

# 测试集只使用一次

1. 留出独立测试集，分类采用分层划分.
2. 训练集内部做 $k$ 折交叉验证.
3. Pipeline 同时拟合预处理与模型.
4. 用预先确定的指标选择超参数.
5. 锁定参数后报告一次测试性能.

# Notebook 实践

1. **糖尿病数据**：回归、残差与指标.
2. **高维模拟**：比较 OLS、Ridge、Lasso.
3. **乳腺癌数据**：Logistic、L1 Logistic、Linear SVM.
4. Pipeline + GridSearchCV：**可靠选择** $\alpha$ **或** $C$.

# 小结

- 线性模型是快速、可解释的重要模型.
- Ridge 求稳定，Lasso 求稀疏；都需正确缩放与验证.
- Logistic 与 Linear SVM 学习线性边界.
- 可靠结论来自无泄漏 Pipeline、交叉验证和独立测试集.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录
- 条件数平方问题
- ROC-AUC：二分类模型的区分能力评价

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

条件数平方问题

ROC-AUC：二分类模型的区分能力评价

# 最小二乘法中的条件数平方问题:

最小二乘法的目标是

$$\min_{\mathbf{w}} \|A\mathbf{w} - \mathbf{y}\|_2^2.$$

通过求导得到正规方程（Normal Equation）：$A^T A\mathbf{w} = A^T\mathbf{y}$.
**问题**：构造 $A^T A$ 会使矩阵的条件数平方.
对于满列秩矩阵 $A$，其条件数定义为

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)},$$

$\sigma_{\max}$ 和 $\sigma_{\min}$ 分别为最大和最小奇异值.
由奇异值分解 $A = U\Sigma V^T$，有 $A^T A = V\Sigma^T\Sigma V^T$.
因此，

$$\boxed{\kappa_2(A^T A) = \frac{\sigma_{\max}^2}{\sigma_{\min}^2} = [\kappa_2(A)]^2}$$

## 核心结论

正规方程会将条件数平方，从而增加数值求解对舍入误差的敏感程度.

# 条件数平方的后果与解决方法

**1. 数值误差可能被显著放大**

| $\kappa_2(A)$ | $\kappa_2(A^TA)$ | 数值风险 |
|---|---|---|
| $10^2$ | $10^4$ | 较低 |
| $10^4$ | $10^8$ | 较高 |
| $10^6$ | $10^{12}$ | 严重 |
| $10^8$ | $10^{16}$ | 接近双精度极限 |

双精度浮点数的机器精度约为 $\epsilon_{\text{mach}} \approx 2.2 \times 10^{-16}$.

**2. 推荐采用 QR 或 SVD 分解**

- **QR 分解**：$A = QR$，通过 $R\mathbf{w} = Q^T\mathbf{y}$ 求解（满列秩情形）.
- **SVD 分解**：$A = U\Sigma V^T$，通过伪逆 $\mathbf{w} = A^+\mathbf{y}$ 求解.
- 两者均避免显式构造 $A^TA$，具有更好的数值稳定性.

## Python 实践

推荐使用 `np.linalg.lstsq(A, y, rcond=None)`，别直接算 $(A^TA)^{-1}A^T\mathbf{y}$.

1 线性回归

2 正则化回归

3 线性分类

4 模型的评价

5 附录

条件数平方问题

ROC-AUC：二分类模型的区分能力评价

# ROC 曲线：分类阈值与分类性能

**ROC（Receiver Operating Characteristic）曲线（受试者操作特征曲线）**：通过改变二分类模型的决策阈值，考察真正率（TPR）与假正率（FPR）之间的关系.

**核心指标**：

$$\boxed{\mathrm{TPR} = \frac{TP}{TP + FN} \qquad \mathrm{FPR} = \frac{FP}{FP + TN}}$$

- TPR：实际正类中被正确识别的比例，即 Recall（召回率）.
- FPR：实际负类中被错误识别为正类的比例.

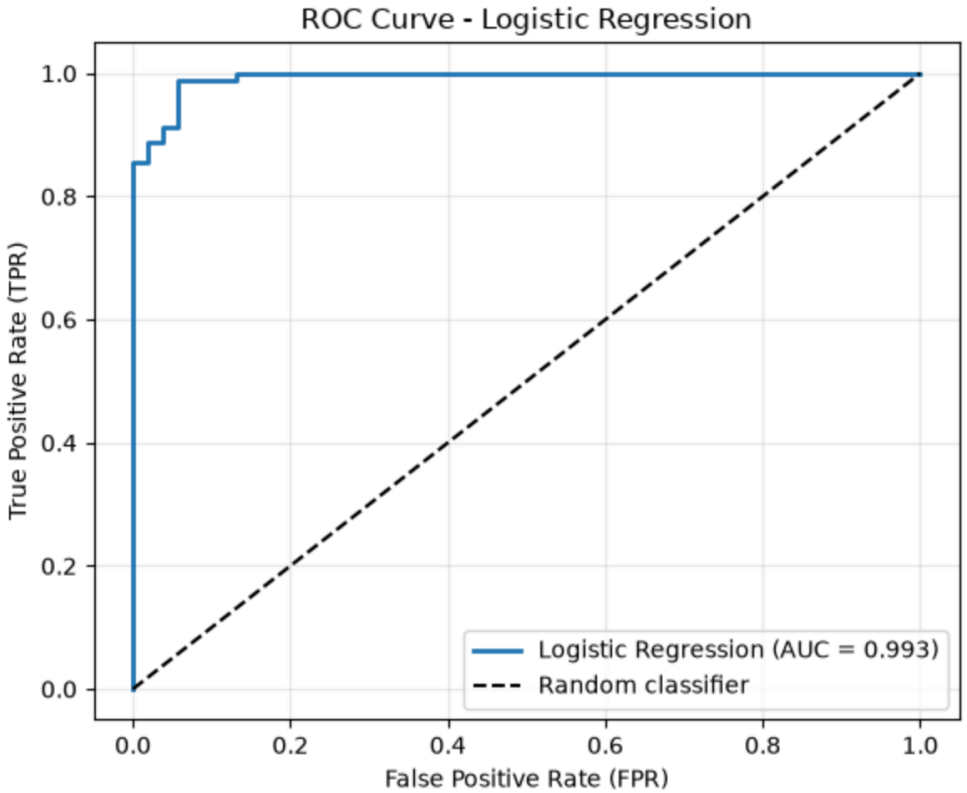
**ROC 曲线的构造过程**：

1. 模型为每个样本输出正类预测概率 $p_i$.
2. 选择分类阈值 $t$，若 $p_i \geq t$，则预测为正类.
3. 计算该阈值对应的 $(\mathrm{FPR}, \mathrm{TPR})$.
4. 改变阈值 $t$，连接得到的点，形成 ROC 曲线.

# ROC 曲线：分类阈值与分类性能 (2)

## 如何理解 ROC 曲线？

横坐标为 FPR，纵坐标为 TPR. 曲线越靠近左上角 $(0,1)$，分类器的区分能力通常越强. 对角线表示随机排序基准（如下图所示）.



# AUC：ROC 曲线下面积及其统计意义（1）

**AUC（Area Under the Curve）**：ROC 曲线下面积，用于评价模型对正负样本的整体区分能力.

$$\boxed{\mathrm{AUC} = \int_0^1 \mathrm{TPR}(u)\, du, \qquad u = \mathrm{FPR}}$$

**AUC 的统计学解释**：
随机抽取一个正类样本和一个负类样本，AUC 表示模型将正类排在负类前面的概率（并列得分按一半计算）：

$$\boxed{\mathrm{AUC} = P(s_+ > s_-) + \frac{1}{2} P(s_+ = s_-)}$$

其中 $s_+$ 和 $s_-$ 分别为正类与负类的预测得分.

# AUC：ROC 曲线下面积及其统计意义 (2)

**简单例子：**

$$\text{正类得分：} \quad 0.9,\ 0.8,\ 0.6$$
$$\text{负类得分：} \quad 0.7,\ 0.4,\ 0.2$$

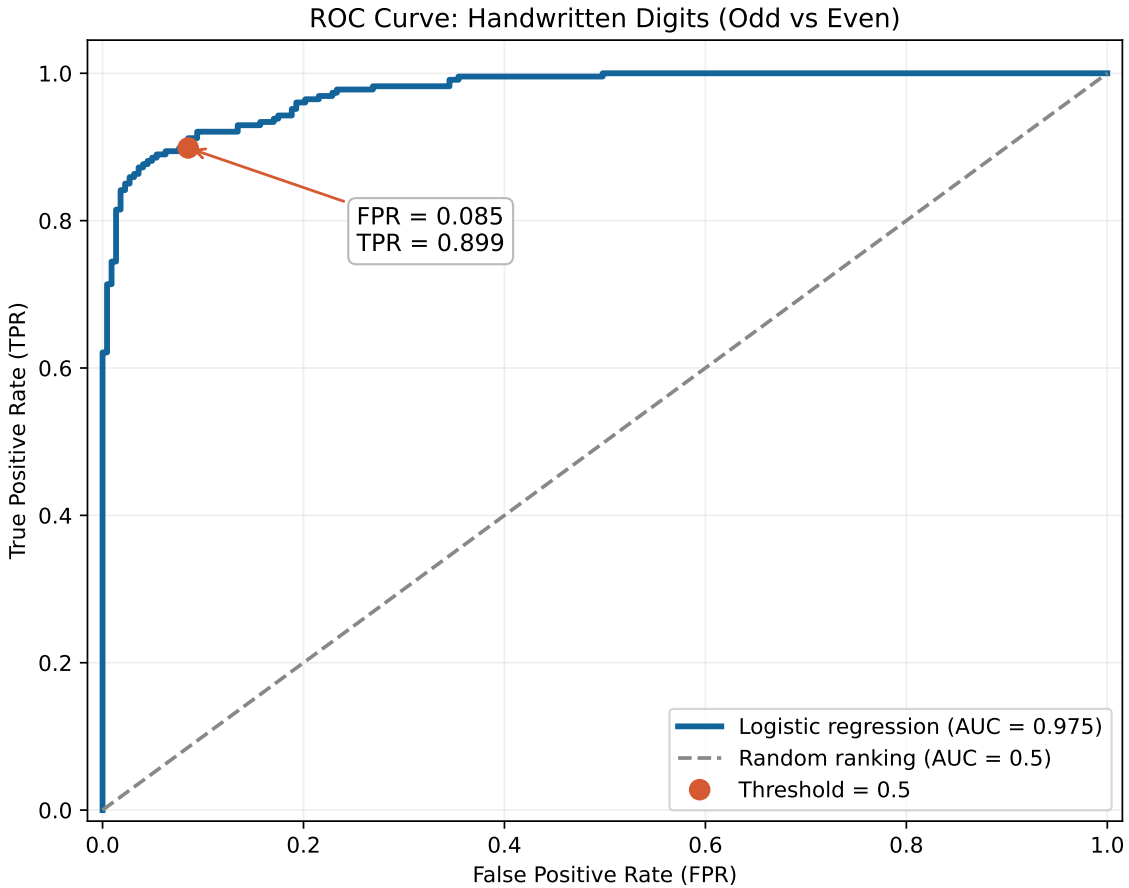
**共有 $3 \times 3 = 9$ 对正负样本，其中 $3 + 3 + 2 = 8$ 对排序正确. 因此，**

$$\text{AUC} = \frac{8}{9} \approx 0.889$$

## 核心结论

AUC=1 表示完美排序，AUC=0.5 对应随机排序水平.
**AUC=0.9** 不意味着分类准确率为 **90%.** AUC 评价的是排序能力，非预测概率的校准程度.

# ROC-AUC：真实手写数字分类实验




Test set: 450 images | Positive class: odd digits (1, 3, 5, 7, 9)

**逻辑回归对手写数字进行奇偶分类：测试集** Accuracy $= 0.911$，ROC-AUC $= 0.975$. **(见 Notebook)**