

阅读材料 1：数学知识

《AI 在科学中的应用》

2026, June, 16

1 线性代数基础

1.1 内容

本节主要包括以下内容：线性代数中的概念和基本运算；在 Python 语言中实现线性代数中的运算。

1.2 基本概念

1.2.1 矢量

数学上看，矢量空间的元素，或矢量空间中的点，就是**矢量**。更具体地看，有序的值的序列就构成了一个矢量。一般用小写黑体字母表示，如

$$\mathbf{x} = \begin{pmatrix} 2 \\ 3 \end{pmatrix} = (2, 3)^T,$$

是二维空间中的矢量。我们默认采用笛卡尔坐标系。

又如

$$\mathbf{y} = \begin{pmatrix} 1.0 \\ 1.0 \\ 1.0 \end{pmatrix}$$

是三维空间中的矢量。

矢量的元素用下标标识，例如

$$x_1 = 2, \quad x_2 = 3.$$

注意：

1. 我们所在的三维空间可以近似看作一个三维矢量空间。取定某点为原点，那么空间中的每一点就可以对应于该空间中的一个矢量。所有这些矢量构成这个三维空间本身。

2. 在学习 Python 时，需要区分列表 [2,3]、元组 (2,3) 和数学中的矢量

$$\mathbf{x} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}.$$

1.2.2 矢量的基本操作

矢量加法 例如，

$$\mathbf{x} + \mathbf{z} = \begin{pmatrix} 2 \\ 3 \end{pmatrix} + \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}.$$

一般地，对于两个二维矢量求和，结果为对应坐标分别相加：

$$\mathbf{a} + \mathbf{b} = \begin{pmatrix} a_1 + b_1 \\ a_2 + b_2 \end{pmatrix}.$$

需要注意：

1. 只有维度相同的两个矢量才可以相加；
2. 对于高维空间中的矢量求和，可以依此类推。

矢量的数乘 已知常数

$$\lambda \in R,$$

以及一个 n 维矢量 $\mathbf{x}$ ，数乘定义为

$$\lambda \mathbf{x} = \lambda \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} \lambda x_1 \\ \lambda x_2 \\ \vdots \\ \lambda x_n \end{pmatrix}.$$

例如，矢量

$$\mathbf{y} = \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

数乘可写为

$$0.707\mathbf{x} = 0.707 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix}.$$

说明：

1. 当常数的绝对值大于 1 时，数乘会将矢量**伸长**；当常数的绝对值小于 1 时，数乘会将矢量**缩短**。
2. 常数可以是**实数**，也可以是复数。

矢量的长度 矢量的长度又称为矢量的模。例如，对于

$$\mathbf{x} = \begin{pmatrix} 3 \\ 4 \end{pmatrix},$$

有

$$|\mathbf{x}| = \sqrt{3^2 + 4^2} = 5.$$

通常，**矢量长度**定义为各元素平方和的平方根。

矢量的点积 两个矢量的点积，又称为标量积。

例如，对于二维矢量 $\mathbf{x}$ 和 $\mathbf{y}$ ，其点积为

$$\mathbf{x} \cdot \mathbf{y} = x_1 y_1 + x_2 y_2.$$

例如，

$$\mathbf{x} = \begin{pmatrix} 4 \\ 5 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

则

$$\mathbf{x} \cdot \mathbf{y} = 4 \times 1 + 5 \times 0 = 4.$$

注意：

1. 矢量的点积满足**交换律**：

$$\mathbf{x} \cdot \mathbf{y} = \mathbf{y} \cdot \mathbf{x}.$$

2. 在书写矢量点积的表达式时，点积符号不能省略：

$$\mathbf{x} \cdot \mathbf{y} \neq \mathbf{xy}.$$

3. 举例来说，一个人具有年龄、性别、身高、体重、职业、收入、母语和国籍等特征。每一个特征都可以看作一个维度，每个维度上的信息可以用数字进行编码。

例如，可以写成

$$V_{\text{person}} = \begin{pmatrix} 24 \\ F \\ 170 \\ 60 \\ OL \\ 5.5 \\ Chinese \\ CN \end{pmatrix} \longrightarrow \begin{pmatrix} 24 \\ 0 \\ 170 \\ 60 \\ 3 \\ 5.5 \\ 1 \\ 3 \end{pmatrix}.$$

严格来说，这些物理量具有不同的单位，因此直接组合起来并不一定构成通常数学意义下的矢量。但是如果进行适当的单位处理和编码，就可以将这些数据表示成数值空间中的一个矢量。

4. 同理, 对于网页上的一篇文章、交易数据, 甚至一般的数据对象, 我们都可以尝试将其表示成一个矢量。例如, 利用 Bag-of-Words (词袋) 方法, 可以把两篇文章分别表示成矢量。通过计算两个矢量之间的差异或点积, 就可以分析两篇文章的相似程度, 从而用于文章分类、相似文本检索以及抄袭检测等任务 (习题)。

1.2.3 矩阵

由特定行数和列数的数构成的数学对象称为**矩阵**。

例如,

$$X = \begin{pmatrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \end{pmatrix}$$

是一个 2×3 矩阵。

又如,

$$X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix},$$

都是 2×2 矩阵。

一般地, 一个 $M \times N$ 的矩阵由 $M \times N$ 个数排列成 M 行 N 列组成, 其中 M, N 都是大于或等于 1 的整数。

矩阵可以描述对一个对象的操作, 而这里的对象往往可以用一个矢量来描述。矩阵作用在矢量上, 可以产生新的数学对象。矩阵本身也可以用来描述一个对象或者状态, 为实际问题建立模型。

一个 M 维列矢量也可以看作一个 $M \times 1$ 矩阵。

矩阵的分量用两个下标标注。第一个下标表示行, 第二个下标表示列, 例如 A_{ij} 表示矩阵 A 的第 i 行、第 j 列元素。在程序中往往写作

$$A[i][j].$$

1.2.4 矩阵的基本操作

矩阵的和 如果矩阵 A 和 B 具有相同的形状, 则 A 与 B 的和定义为

$$(A + B)_{ij} = A_{ij} + B_{ij}.$$

也就是说, 两个矩阵对应位置上的元素分别相加。

矩阵的数乘 矩阵的数乘计算公式为

$$(\lambda A)_{ij} = \lambda A_{ij}.$$

例如,

$$5 \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 5 \times 1 & 5 \times 0 \\ 5 \times 0 & 5 \times (-1) \end{pmatrix} = \begin{pmatrix} 5 & 0 \\ 0 & -5 \end{pmatrix}.$$

矩阵的乘法 不是任意两个矩阵都可以进行矩阵乘法。只有当第一个矩阵的列数等于第二个矩阵的行数时，二者的矩阵乘法才有定义。

例如，

$$AB = \begin{pmatrix} 0 & 1 & 2 \\ 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 2 & 3 \\ 4 & 5 \end{pmatrix}.$$

根据矩阵乘法的定义，

$$AB = \begin{pmatrix} 0 \times 0 + 1 \times 2 + 2 \times 4 & 0 \times 1 + 1 \times 3 + 2 \times 5 \\ 3 \times 0 + 4 \times 2 + 5 \times 4 & 3 \times 1 + 4 \times 3 + 5 \times 5 \end{pmatrix}.$$

因此，

$$AB = \begin{pmatrix} 10 & 13 \\ 28 & 40 \end{pmatrix}.$$

一个 2×3 矩阵乘以一个 3×2 矩阵，得到一个 2×2 矩阵。

又如，

$$X\mathbf{a} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \times 1 + 1 \times 0 \\ 1 \times 1 + 0 \times 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

一个 2×2 矩阵乘以一个 2×1 矩阵，得到一个 2×1 矩阵，即结果仍然可以看作一个矢量。

再举两个例子：

$$Z\mathbf{a} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \times 1 + 0 \times 0 \\ 0 \times 1 + (-1) \times 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

以及

$$Z\mathbf{b} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \times 1 + 0 \times 1 \\ 0 \times 1 + (-1) \times 1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

在第一个例子中，矩阵 Z 作用在 $\mathbf{a}$ 上之后，结果仍然是原来的矢量。而矩阵 Z 作用在 $\mathbf{b}$ 上之后，则得到一个新的矢量。

矩阵乘法具有以下性质：

1. 对于一般矩阵，矩阵乘法**不满足交换律**。即对于矩阵 A 和 B ，一般有

$$AB \neq BA.$$

一个直观的例子是：假设你位于赤道上的一点 $\mathbf{x}$ 。如果先向东走 1000 km，再向北走 1000 km，到达一点 $\mathbf{y}$ ；而如果先向北走 1000 km，再向东走 1000 km，则可能到达另外一点 $\mathbf{z}$ 。两种操作交换顺序之后，最终结果并不一定相同。

类似地，两次转动魔方的顺序发生交换时，最终得到的魔方状态也可能不同。

2. 矩阵乘法**满足结合律**。对于矩阵 A, B, C ，

$$(AB)C = A(BC).$$

转置矩阵 矩阵 A 的**转置矩阵**定义为

$$(A^T)_{ij} = A_{ji}.$$

例如,

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \implies A^T = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}.$$

二维列矢量可以看作 2×1 矩阵, 因此同样可以计算其转置。例如,

$$\mathbf{x} = \begin{pmatrix} 4 \\ 5 \end{pmatrix} \implies \mathbf{x}^T = (4 \ 5).$$

利用转置矩阵, 矢量的点积可以用矩阵乘法的形式表示:

$$\mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T \mathbf{y}.$$

例如,

$$\mathbf{x} \cdot \mathbf{y} = (4 \ 5) \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 4 \times 1 + 5 \times 0 = 4.$$

逆矩阵 单位矩阵 I 定义为

$$I_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

它是一个 $N \times N$ 方阵。

单位矩阵具有性质

$$AI = IA = A.$$

例如,

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}.$$

对于一个方阵 A , 它的逆矩阵 A^{-1} 定义为

$$A^{-1}A = I.$$

对于奇异矩阵, 其逆矩阵不存在。

解线性方程组 矩阵可以用来表示和求解线性方程组。例如, 方程组

$$\begin{cases} x + y = 35, \\ 2x + 4y = 94. \end{cases}$$

可以写成矩阵形式：

$$\begin{pmatrix} 1 & 1 \\ 2 & 4 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 35 \\ 94 \end{pmatrix}.$$

也就是

$$A\mathbf{x} = \mathbf{b}.$$

如果矩阵 A 可逆，则可以在方程两边从左侧乘以 A^{-1} ：

$$A^{-1}A\mathbf{x} = A^{-1}\mathbf{b}.$$

因此

$$\mathbf{x} = A^{-1}\mathbf{b}.$$

这给出了利用矩阵语言表示线性方程组的一种通用形式。

2 张量

张量 (tensor) 可以首先从标量、向量和矩阵的推广来理解。一个**标量**只包含一个数，例如温度

$$T = 300 \text{ K}.$$

一个**向量**包含若干分量，例如三维空间中的速度

$$\mathbf{v} = (v_x, v_y, v_z).$$

一个**矩阵**可以写成具有两个指标的对象

$$A_{ij}.$$

进一步推广，如果一个对象具有更多指标，例如

$$T_{ijk}, \quad T_{ijkl},$$

则可以将其看作更高阶的张量。因此，从计算的角度，可以将张量理解为：张量是标量、向量和矩阵向更高维数组的推广。例如，

$$0 \text{ 阶张量: } a,$$

$$1 \text{ 阶张量: } v_i,$$

$$2 \text{ 阶张量: } A_{ij},$$

$$3 \text{ 阶张量: } T_{ijk}.$$

2.1 数学和物理中的定义

在数学和物理中，张量并不只是一个多维数组。更本质地说，张量是在坐标变换下按照特定规律变换的数学对象。例如，对于一个二阶张量 T_{ij} ，在坐标变换后，其分量通常满足

$$T'_{ij} = \sum_{k,l} R_{ik} R_{jl} T_{kl},$$

其中 R 表示坐标变换矩阵。

因此，并不是所有多维数组都可以称为严格意义上的张量。只有当其分量在坐标变化时满足相应的张量变换规律时，它才是一个真正的张量。

2.2 物理中的例子

在物理学中，许多重要物理量都需要用张量来表示，例如：

- 应力张量 σ_{ij} ;
- 应变张量 ε_{ij} ;
- 转动惯量张量 I_{ij} ;
- 电磁场张量 $F_{\mu\nu}$.

以应力张量为例，一个物体内部某一点上的应力不能只用一个数来描述，因为应力不仅有大小和方向，而且还依赖于所考虑截面的方向。

因此通常写成 σ_{ij} 。其中，一个指标可以表示力的方向，另一个指标可以表示截面法向的方向。因此，应力自然需要用一个二阶张量来描述。在一个特定方向的外场下，系统的响应在各个方向有不同。因此，这种响应有必要用张量来描述。

2.3 机器学习中的张量

在机器学习中，“tensor”这个词通常使用得更加宽泛，主要指**多维数组**。例如，一张 RGB 彩色图像可以写成

$$X \in R^{H \times W \times 3},$$

其中， H 表示图像高度； W 表示图像宽度；3 表示红、绿、蓝三个颜色通道。

在 PyTorch、TensorFlow 等机器学习框架中，这样的对象通常就称为一个张量。因此，可以区分两种不同的语境：在机器学习中，

张量 $\approx$ 多维数组

而在数学和物理中，

张量 = 满足特定坐标变换规律的数学对象。

在人工智能课程中，可以先把张量理解为“多维数组”；在数学和物理中，张量还有更加严格的坐标变换定义。

3 秩-零化度定理

秩-零化度定理 (Rank-Nullity Theorem) 是线性代数中最基本的定理之一 (是 Π 定理的数学基础)。它描述了一个线性映射的输入空间维数、像空间维数以及核空间维数之间的关系。设

$$T: V \rightarrow W$$

是有限维向量空间之间的线性映射，则有

$$\dim V = \text{rank}(T) + \text{nullity}(T).$$

其中，

$$\text{rank}(T) = \dim(\text{Im } T)$$

称为线性映射 T 的秩，它表示像空间的维数，也就是线性映射能够产生多少个线性独立的输出方向；而

$$\text{nullity}(T) = \dim(\ker T)$$

称为零化度，它表示核空间的维数，也就是有多少个线性独立的输入方向会被映射为零。因此，秩-零化度定理可以直观地理解为：

$$\text{输入自由度} = \text{保留下来的自由度} + \text{被压缩掉的自由度}.$$

其中，秩对应于经过线性变换后仍然保留在输出空间中的独立方向，而零化度则对应于被线性映射完全压缩到零向量的独立方向。

例

考虑矩阵

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

它定义了线性映射

$$T: R^3 \rightarrow R^2, \quad T(\mathbf{x}) = A\mathbf{x}.$$

输入空间的维数为

$$\dim R^3 = 3.$$

由于矩阵 A 的两行线性独立，因此

$$\text{rank}(A) = 2.$$

接下来求其核空间。令

$$A \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

则得到

$$x + z = 0, \quad y + z = 0.$$

因此

$$x = -z, \quad y = -z,$$

从而

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = z \begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix}.$$

因此核空间可以写为

$$\ker A = \text{span} \left\{ \begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix} \right\},$$

所以

$$\text{nullity}(A) = 1.$$

于是有

$$3 = 2 + 1,$$

即

$$\dim R^3 = \text{rank}(A) + \text{nullity}(A),$$

与秩-零化度定理完全一致。

几何理解

对于上述映射

$$T: R^3 \rightarrow R^2,$$

可以将其理解为把三维空间压缩到二维空间。其中方向

$$\begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix}$$

被映射为零，即

$$A \begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

因此，这个方向属于核空间。整个三维输入空间中的自由度被分成两部分：二维自由度保留在像空间中，另一维自由度则被压缩到零。因此可写成

$$\boxed{3\text{维输入} = 2\text{维有效输出} + 1\text{维被压缩的方向}}.$$

这正是秩-零化度定理的几何意义。

矩阵形式

对于矩阵

$$A \in R^{m \times n},$$

它定义了线性映射

$$A : R^n \rightarrow R^m.$$

此时秩-零化度定理写为

$$\boxed{n = \text{rank}(A) + \dim(\ker A)}.$$

这里需要特别注意，等式左边是矩阵的列数 n ，而不是行数 m ，因为 n 正是输入空间 R^n 的维数。

因此可以将该公式记忆为

$$\boxed{\text{列数} = \text{秩} + \text{零空间维数}}.$$

与单射的关系

如果

$$\text{nullity}(T) = 0,$$

那么

$$\ker T = \{\mathbf{0}\}.$$

这意味着不存在非零向量被映射为零，因此 T 是单射 (injective)。

根据秩-零化度定理，

$$\dim V = \text{rank}(T) + 0,$$

于是

$$\text{rank}(T) = \dim V.$$

因此，秩-零化度定理也揭示了线性映射的核、秩以及单射性质之间的直接联系。

4 线性代数基本定理与四个基本子空间

秩-零化度定理可以进一步推广到线性代数中一个更完整的结构，即**线性代数基本定理** (Fundamental Theorem of Linear Algebra)。对于任意矩阵

$$A \in R^{m \times n},$$

可以考虑与它相关的四个基本子空间：

$$\boxed{\text{Col}(A), \quad \text{Row}(A), \quad \ker(A), \quad \ker(A^T)}$$

它们分别称为：

- 列空间 (column space);
- 行空间 (row space);
- 零空间 (null space);
- 左零空间 (left null space)。

这四个空间共同描述了矩阵 A 作为一个线性映射的完整几何结构。

列空间

矩阵

$$A \in R^{m \times n}$$

可以看成线性映射

$$A : R^n \rightarrow R^m.$$

它的列空间定义为

$$\text{Col}(A) = \{A\mathbf{x} \mid \mathbf{x} \in R^n\}.$$

因此，

$$\text{Col}(A) = \text{Im}(A),$$

也就是线性映射 A 的像空间。它是输出空间 R^m 的一个子空间，并且

$$\dim \text{Col}(A) = \text{rank}(A).$$

因此，**矩阵的秩**可以理解为**列空间中线性独立方向的数目**。

零空间

零空间定义为

$$\ker(A) = \{\mathbf{x} \in R^n \mid A\mathbf{x} = 0\}.$$

它是输入空间 R^n 的子空间。其维数为

$$\dim \ker(A) = \text{nullity}(A).$$

根据秩-零化度定理,

$$\dim \text{Col}(A) + \dim \ker(A) = n.$$

也就是说,

$$\text{rank}(A) + \text{nullity}(A) = n.$$

因此, 在输入空间 R^n 中, 总共有 n 个自由度, 其中一部分通过线性映射保留下来, 形成列空间; 另一部分则被映射到零, 形成零空间。

行空间

矩阵 A 的行空间定义为其所有行向量张成的空间:

$$\text{Row}(A) = \text{span}\{\text{rows of } A\}.$$

由于 A 的每一行有 n 个分量, 因此

$$\text{Row}(A) \subseteq R^n.$$

一个非常重要的结论是

$$\dim \text{Row}(A) = \dim \text{Col}(A) = \text{rank}(A).$$

也就是说:

$$\text{行秩} = \text{列秩}.$$

这也是为什么我们通常只说矩阵的“rank”, 而不需要区分行秩和列秩。

左零空间

左零空间定义为

$$\ker(A^T) = \{\mathbf{y} \in R^m \mid A^T \mathbf{y} = 0\}.$$

等价地, 也可以写成

$$\mathbf{y}^T A = 0.$$

因为

$$A^T : R^m \rightarrow R^n,$$

所以对 A^T 使用秩-零化度定理, 有

$$m = \text{rank}(A^T) + \dim \ker(A^T).$$

又因为

$$\text{rank}(A^T) = \text{rank}(A),$$

因此

$$m = \text{rank}(A) + \dim \ker(A^T).$$

所以

$$\dim \ker(A^T) = m - \text{rank}(A).$$

四个基本子空间的维数关系

设

$$\text{rank}(A) = r.$$

那么四个基本子空间的维数分别为

$$\dim \text{Col}(A) = r,$$

$$\dim \text{Row}(A) = r,$$

$$\dim \ker(A) = n - r,$$

以及

$$\dim \ker(A^T) = m - r.$$

因此可以总结为

$$\begin{aligned} \text{Col}(A) &\subseteq R^m, & \dim \text{Col}(A) &= r, \\ \text{Row}(A) &\subseteq R^n, & \dim \text{Row}(A) &= r, \\ \ker(A) &\subseteq R^n, & \dim \ker(A) &= n - r, \\ \ker(A^T) &\subseteq R^m, & \dim \ker(A^T) &= m - r. \end{aligned}$$

正交关系

线性代数基本定理中还有两个非常重要的正交关系。首先,

$$\text{Row}(A) = \ker(A)^\perp.$$

也就是说，**行空间和零空间互为正交补**。这是因为如果

$$\mathbf{x} \in \ker(A),$$

那么

$$A\mathbf{x} = 0.$$

矩阵乘法实际上表示 A 的每一个行向量与 $\mathbf{x}$ 做内积，因此

$$\mathbf{r}_i \cdot \mathbf{x} = 0$$

对所有行向量 $\mathbf{r}_i$ 都成立。于是 $\mathbf{x}$ 与整个行空间正交。

类似地，

$$\boxed{\text{Col}(A) = \ker(A^T)^\perp}.$$

也就是说，**列空间和左零空间互为正交补**。因此可以写成两个正交分解：

$$\boxed{R^n = \text{Row}(A) \oplus \ker(A)}$$

以及

$$\boxed{R^m = \text{Col}(A) \oplus \ker(A^T)}.$$

这里的符号 $\oplus$ 表示直和，而且在这里是正交直和。

几何意义

这两个分解具有非常清楚的几何意义。对于任意输入向量

$$\mathbf{x} \in R^n,$$

都可以唯一分解为

$$\mathbf{x} = \mathbf{x}_{\text{row}} + \mathbf{x}_{\text{null}},$$

其中

$$\mathbf{x}_{\text{row}} \in \text{Row}(A), \quad \mathbf{x}_{\text{null}} \in \ker(A).$$

应用矩阵 A 后，

$$A\mathbf{x} = A\mathbf{x}_{\text{row}} + A\mathbf{x}_{\text{null}}.$$

由于

$$A\mathbf{x}_{\text{null}} = 0,$$

因此

$$A\mathbf{x} = A\mathbf{x}_{\text{row}}.$$

这说明：

矩阵 A 只对输入向量在行空间方向上的分量敏感。

而输入中位于零空间方向上的分量，对输出完全没有影响。同样地，在输出空间 R^m 中，只有列空间中的方向能够由

$$A\mathbf{x}$$

产生，而左零空间中的方向永远无法由该线性映射产生。

与线性方程组的关系

考虑线性方程组

$$A\mathbf{x} = \mathbf{b}.$$

该方程有解的充要条件是

$$\mathbf{b} \in \text{Col}(A).$$

也就是说，右端向量 $\mathbf{b}$ 必须位于矩阵的列空间中。如果存在一个特解

$$\mathbf{x}_p$$

满足

$$A\mathbf{x}_p = \mathbf{b},$$

那么所有解都可以写成

$$\mathbf{x} = \mathbf{x}_p + \mathbf{x}_n$$

其中

$$\mathbf{x}_n \in \ker(A).$$

因为

$$A(\mathbf{x}_p + \mathbf{x}_n) = A\mathbf{x}_p + A\mathbf{x}_n = \mathbf{b} + 0 = \mathbf{b}.$$

因此，零空间描述了线性方程组解的不唯一性。如果

$$\ker(A) = \{0\},$$

那么只要方程有解，该解就是唯一的。

统一理解

线性代数基本定理可以理解为对一个矩阵 A 的输入空间和输出空间进行完整分解：

$$R^n = \text{Row}(A) \oplus \ker(A)$$

描述输入空间，而

$$R^m = \text{Col}(A) \oplus \ker(A^T)$$

描述输出空间。其中

$$\text{Row}(A) \longrightarrow \text{Col}(A)$$

描述了真正参与线性变换的有效自由度，而

$$\ker(A)$$

描述输入中被线性变换完全忽略的方向。

秩-零化度定理并不是一个孤立的维数公式，而是更完整的线性代数几何结构的一部分。它揭示了矩阵如何将输入空间中的自由度分成‘有效方向’和‘消失方向’，以及这些方向如何与输出空间中的可达方向和不可达方向对应起来。

5 数据集

数据集的特征和标签都可以用矩阵来表示。特征矩阵的行数为样本数，列数为特征数。标签一般为列矩阵，其分量个数为样本数。举例如下：

$$X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 \end{pmatrix} \in \{0, 1\}^{10 \times 6}$$

$$\mathbf{y} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \in \{0, 1\}^{10}$$

习题

(5 分) 假设我们有一本词典，其中只有五个单词

$$[a, b, c, d, e].$$

现有三个文档：

- 文档 A：

$$[a, b, b, d, d, e];$$

- 文档 B：

$$[b, b, b, e, e, e, d, a];$$

- 文档 C：

$$[d, b, b, e].$$

使用 Bag-of-Words (词袋) 模型将每个文档表示成一个五维向量，每个维度上的分量分别表示单词 a, b, c, d, e 在文档中出现的次数。例如，文档 A 可以表示为

$$\mathbf{a} = \begin{pmatrix} 1 \\ 2 \\ 0 \\ 2 \\ 1 \end{pmatrix}.$$

1. 将文档 B 和文档 C 按照上述模型分别表示成向量。
2. 若定义两个向量夹角的余弦值为这两个向量所对应文档的 **相似性**，计算文档 A 与文档 B 的相似性，以及文档 A 与文档 C 的相似性。